



به نام خدا



دانشگاه تهران

دانشکده مهندسی برق و کامپیوتر

هوش مصنوعی قابل اعتماد

تمرین دوم

نام و نام خانوادگی	زکيه امين
شماره دانشجویی	810102398

سؤال اول: تفسیر پذیری

بخش اول : سوالات توضیحی

1. زیربخش اول: PDP

الف) در روش PDP مقدار x_S رو برای همه نمونه ها ثابت قرار میدیم و این نمونه ها رو به مدل میدیم. اگه S و C همبستگی زیادی داشته باشند، وقتی S مقداری خاص است، C در محدوده خاصی قرار میگیرد. این در حالی است که PDP ترکیب هایی از S و C میسازد که غیرواقعی هستند و بدون توجه به این وابستگی همه مقادیر C را با x_S های fixed شده ترکیب میکند. پس مدل روی داده های غیرواقعی ارزیابی میشود، اثر واقعی S ممکن است به درستی تشخیص داده نشود، چون همبستگی در نظر گرفته نشده. پس به طور کلی تفسیر PDP میتونه اشتباه باشه.

ب) روش Accumulated Local Effects (ALE) برای رفع مشکلات ناشی از همبستگی بین متغیرهای پیش‌بین در ML استفاده میشود. در روش Partial Dependence – PD، اثر یک متغیر (X_1) با میانگین گرفتن از مقدار تابع پیش‌بینی روی توزیع حاشیه‌ای متغیر دیگر (X_2) محاسبه میشود. زمانی که بین دو متغیر همبستگی وجود دارد مدل مجبور به برون‌یابی (extrapolation) می‌شود که منجر به پیش‌بینی‌های غیرقابل اعتماد و نتیجه نادرست می‌گردد. روش M از توزیع شرطی ($X_2|X_1$) استفاده می‌کند و مشکل برون‌یابی رو حل میکند. اما این روش دچار سوگیری ناشی از متغیر حذف‌شده (Omitted Variable Bias) می‌شود. یعنی در اثر X_1 اثر متغیر همبسته X_2 هم در نتایج وجود داره و نمودار M نمی‌تواند اثر خالص و واقعی X_1 را درست جدا و تفسیر کند. روش ALE هر دو مشکل را برطرف می‌کند. ایده‌ی اصلی این است که به‌جای بررسی مقدار خود تابع پیش‌بینی، مشتق محلی آن نسبت به متغیر مورد نظر مورد توجه قرار گیرد. این تغییرات تنها در نقاطی محاسبه می‌شوند که داده‌های واقعی وجود دارند و نیازی به برون‌یابی نیست. بعد این تغییرات محلی برای هر مقدار متغیر روی توزیع شرطی $p(x_2|x_1)$ میانگین‌گیری می‌شوند که تاثیر هر متغیر با در نظر گرفتن متغیرهای همبسته و در محدوده‌های واقعی داده‌ها محاسبه می‌شود. در آخر، این اثرات محلی میانگین‌گیری‌شده از حد پایین تا مقدار دلخواه X_1 انباشته می‌شن و اثر نهایی X_1 به دست می‌آید.

ج) خیر. خط افقی در PDP به این معناست که اثر میانگین X_1 روی پیش‌بینی خروجی صفر است، اما حتماً به این معنی نیست که مدل به X_1 اهمیت نمی‌دهد یا از آن استفاده نکرده. ممکن است ویژگی X_1 با سایر ویژگی‌ها روابط پیچیده‌ای داشته باشد، مثلاً اثر مثبت آن در برخی نقاط با اثر منفی در نقاط دیگر خنثی شود. پس میانگین اثرات ممکن است به صورت یک خط افقی (یعنی اثر صفر) ظاهر بشود، در حالی که مدل از X_1 استفاده کرده است. PDP بر اساس میانگین‌گیری از اثرات مدل روی توزیع حاشیه‌ای ویژگی‌ها کار می‌کند. اگر اثر X_1 در مدل به شدت غیرخطی باشد، ممکن است این میانگین‌گیری اثر کلی را پنهان کند. همچنین اگر X_1 با سایر ویژگی‌ها همبستگی داشته باشد، ممکن است به دلیل برون‌یابی‌های غیرواقعی، اثر واقعی ویژگی در نمودار دیده نشود.

2. زیربخش دوم: LIME

روش LIME برای تفسیر مدل‌های پیچیده، یک مدل ساده و قابل تفسیر را به صورت local در اطراف یک نقطه خاص از داده‌ها Train میکند. حتی اگر مدل اصلی بسیار غیرخطی و پیچیده باشد، همیشه رفتارش را با یک مدل خطی تو ناحیه کوچک تقریب زد. این تقریب زمانی قابل اعتماد است که تابع پیش‌بینی مدل جعبه‌سیاه در اطراف نقطه موردنظر رفتار نسبتاً smooth داشته باشد و تغییراتش خیلی ناگهانی نباشد. در چنین حالتی، اگر اندازه همسایگی انتخاب‌شده به اندازه کافی کوچک باشد، مدل خطی می‌تواند شیب و جهت تغییرات تابع را در آن ناحیه به خوبی تقریب بزند. اما اگر تابع در آن ناحیه نوسان شدید و ناپیوستگی داشته باشد، حتی با انتخاب همسایگی کوچک مدل خطی ممکن است نتواند رفتار واقعی مدل را به‌درستی نمایش دهد و در نتیجه گمراه‌کننده باشد. این موضوع مستقیماً به مفهوم Lipschitz بودن مدل جعبه‌سیاه مربوط می‌شود. یک تابع Lipschitz تابعی است که:

$$|F(x) - F(\hat{x})| < L||x - \hat{x}||$$

این یعنی تغییرات تابع به‌صورت کنترل‌شده باشند. اگر مدل جعبه‌سیاه Lipschitz باشد، تغییرات آن در یک ناحیه کوچک از فضای ورودی تقریباً یکنواخت خواهد بود. پس به تقریب خطی محلی می‌تواند رفتار مدل را در آن ناحیه با دقت مناسبی نمایش دهد. LIME به این بستگی دارد که مدل جعبه‌سیاه در اطراف نقطه موردنظر Lipschitz باشد.

3. زیربخش سوم: SHAPLEY VALUE

الف) در روش Shapley value می‌خواهیم سهم هر ویژگی (i) رو حساب کنیم. با توجه به صورت سوال این سهم به صورت زیر محاسبه می‌شود:

$$f(x^i) - E[f(X)]$$

در مدل خطی داریم:

$$f(x^i) = \beta_0 + \beta_1 x_1^i + \dots + \beta_p x_p^i$$

میانگین پیش بینی های مدل نیز به صورت زیر خواهد بود:

$$E[f(X)] = \beta_0 + \beta_1 E[X_1] + \dots + \beta_p E[X_p]$$

پس با اختلاف این دو داریم:

$$f(x^i) - E[f(X)] = \sum_{j=1}^p \beta_j (x_j^i - E[X_j])$$

در مدل خطی، ویژگی‌ها کاملاً *Additive* هستند و *Interaction* بین آن‌ها وجود ندارد، هر ویژگی مستقلاً به اندازه سهم خود در این اختلاف نقش دارد. سهم ویژگی j همان بخشی از معادله است که به این ویژگی مربوطه یعنی:

$$\beta_j (x_j^i - E[X_j])$$

ب) محاسبه دقیق مقادیر *Shapley* برای مدل‌های جعبه‌سیاه به دلیل اینکه تمام زیرمجموعه‌های ممکن از ویژگی‌ها را بررسی میکند، پیچیدگی نمایی $O(2^p)$ دارد. می‌توانیم از خطی‌سازی محلی استفاده کنیم. یعنی به جای تلاش برای محاسبه دقیق *Shapley* در کل فضای مدل، می‌توانیم مدل جعبه‌سیاه را در اطراف نقطه x^i با یک مدل خطی تقریب بزنیم. اگر مدل را به صورت محلی با ضرایب $\hat{\beta}_j$ تقریب بزنیم، طبق بخش الف، می‌توانیم سهم هر ویژگی را به سادگی با فرمول $\beta_j (x_j^i - E[X_j])$ تخمین بزنیم. این کار پیچیدگی نمایی را به یک پیچیدگی بسیار کمتر کاهش می‌دهد.

4. زیربخش چهارم: NAM

معماری NAM یک مدل *Additive* است که در آن هر ویژگی ورودی توسط یک شبکه‌ی عصبی مجزا پردازش می‌شود. پیش‌بینی نهایی مدل به صورت یک ترکیب خطی از خروجی این شبکه‌های تک ویژگی محاسبه می‌شود. این معماری به دلیل جداپذیری اثر ویژگی‌ها تفسیرپذیر است، چون که اثر هر ویژگی بر پیش‌بینی نهایی به ویژگی‌های دیگر وابسته نیست. در نتیجه می‌توان نحوه دقیق تاثیرگذاری آن را بدون ابهام مشاهده کرد.




Figure 1_Architecture of NAM

تفسیرپذیری مدل های NAM به این دلیل ساده است که تاثیر یک ویژگی بر پیش بینی نهایی، به سایر ویژگی ها وابسته نیست و میتوان آن را از طریق رسم Shape Function برای هر ویژگی مشاهده کرد. در نتیجه مشخص میشود مدل دقیقاً به کدام ویژگی ها و به چه شکلی تکیه کرده است.

در مدل های خطی، اثر هر ویژگی یک ضریب ثابت است. به همین خاطر مدل فقط روابط خطی را یاد میگیرد. مزیت NAM این است که ساختار تفسیرپذیر این مدل ها را حفظ کرده و هر یک از شبکه های عصبی تک ویژگی در آن می توانند با استفاده از Back propagation خطا، توابع غیرخطی و پیچیده را برای هر ویژگی یاد بگیرند. NAM هم تفسیرپذیری مدل های خطی رو داره و هم قدرت مدل سازی شبکه های عصبی.

مدل خروجی نهایی را به صورت مجموع اثرات مستقل هر ویژگی محاسبه میکند. این معماری قادر به یادگیری تعاملات پیچیده بین ویژگی ها نیست. اگر خروجی مدل به ترکیب دو یا چند ویژگی وابسته باشد به نحوی که اثر یکی از ویژگی ها با تغییر دیگری تغییر کند، NAM نمی تواند این را مدل کند و در نتیجه ممکن است در مقایسه با مدل های غیرخطی، قدرت پیش بینی کمتری داشته باشد.

برخلاف PDP که برای محاسبه اثر یک ویژگی ممکن است مدل را روی ترکیب های غیرواقعی از ورودی ها ارزیابی کند، NAM با یادگیری ویژگی ها به صورت تک توابع و مستقل، اثر هر متغیر را به صورت مستقیم و بدون نیاز به میانگین گیری روی سایر ویژگی ها نمایش می دهد. از این رو، NAM تا حدی این مشکل رو کاهش میده. هرچند وجود تعاملات پیچیده یا هم بستگی شدید بین ویژگی ها، این محدودیت به طور کامل برطرف نمیشه.

بخش دوم: سوالات پیاده سازی

1. زیربخش اول: مقداردهی مدل

Probability for class cat: 0.905519

2. زیربخش دوم: بخش بندی تصویر

با استفاده از الگوریتم K-Means Clustering، تصویر را به بخش‌های رنگی و مکانی مشابه تقسیم می‌کند. بر اساس تشابه رنگ و نزدیکی مکانی پیکسل‌ها را دسته‌بندی می‌شوند. یعنی پیکسل‌های نزدیک به هم که رنگ مشابهی دارند، در یک دسته قرار می‌گیرند.




Figure 2_Segmentation image

3. زیربخش سوم: تولید نمونه های تغییر یافته




Figure 3_Example perturbed images

4. زیربخش چهارم: وزن دهی تصاویر تغییر یافته

LIME می‌خواهد بفهمد مدل ResNet در اطراف تصویر اصلی چگونه رفتار میکند. با این وزن دهی به تصاویر تغییر یافته ای که شبیه به تصویر اصلی هستند (بخش های بیشتری از تصویر

اصلی را حفظ کرده اند) وزن بیشتری داده می‌شود و به تصاویر تغییر یافته‌ای که بسیار متفاوت هستند (بخش‌های زیادی از آن‌ها حذف شده) وزن کمتری داده می‌شود. این کار باعث می‌شود مدل خطی که آموزش می‌دهیم بر یادگیری رفتار مدل در نزدیکی تصویر اصلی تمرکز کند.




Figure 4 _Distribution of weights

5. زیربخش پنجم: آموزش مدل خطی

برای Feature Selection از رگرسیون Lasso استفاده می‌کنیم. هدف LIME این است که بفهمد کدام بخش‌ها واقعا در تصمیم مدل تاثیرگذار بودند. رگرسیون Lasso به دلیل خاصیت L1، ضرایب غیرضروری را برابر با صفر می‌کند. یعنی فقط چند بخش مهم باقی می‌مانند که واقعا در پیش‌بینی مدل نقش داشتند. Lasso با حذف نویز و ویژگی‌های کم‌اهمیت به ما کمک می‌کند تا بر روی مهم‌ترین قسمت‌های تصویر تمرکز کنیم که همان خروجی تمیز و قابل فهم را می‌سازد.




Figure 5 _Heatmap of cat image

Heatmap به صورت زیر تحلیل می‌شود:

- رنگ آبی (ضرایب مثبت): بخش‌هایی هستند که وقتی در تصویر حضور دارند، باعث افزایش احتمال کلاس ۲۸۲ (گربه) می‌شوند. این یعنی مدل اصلی، این بخش‌ها را به عنوان شواهد قوی برای تشخیص گربه در نظر گرفته است.
 - رنگ قرمز (ضرایب منفی): بخش‌هایی هستند که حضورشان باعث کاهش احتمال کلاس هدف می‌شود. یعنی مدل فکر می‌کند این بخش‌ها متعلق به این کلاس نیستند.
 - رنگ سفید/کمرنگ: بخش‌هایی هستند که ضریب آن‌ها در Lasso صفر شده است و عملاً هیچ تأثیر معناداری بر تصمیم مدل نداشته‌اند.
- با توجه به Heatmap، مدل بر روی بدن و فرم گربه متمرکز شده. پس زمینه تصویر عمدتاً به رنگ سفید است. یعنی مدل به درستی هدف را از محیط تفکیک کرده و وزن‌های مثبت را به Target اختصاص داده. همچنین مدل دور تا دور گربه را با دقت شناسایی کرده.

6. تصویر خرس قطبی

Probability for class polar bear: 0.996435



Figure 6_Heatmap of polar bear image

با توجه به Heatmap، مدل بر روی بدن و فرم خرس قطبی به خصوص ناحیه سر متمرکز شده. پس زمینه تصویر عمدتاً به رنگ آبی کمرنگ است. یعنی مدل با دقت خوبی هدف را از محیط تفکیک کرده و وزن‌های مثبت را به Target اختصاص داده.

با مقایسه این دو Heatmap (گربه و خرس قطبی) داریم:

تصویر گربه: Heatmap شکل کلی گربه را دنبال کرده. مرز بین بدن گربه و پس‌زمینه بسیار دقیق و تیز است. مدل بیشتر روی جزئیات بدن متمرکز است.

تصویر خرس: اگرچه مدل باز هم روی بدن خرس متمرکز است، اما مرزبندی کمی نرم‌تر و پخش‌تر است. این موضوع احتمالاً به این دلیل است که خرس قطبی و برف از نظر رنگی به هم نزدیکند و این کار را برای مدل سخت می‌کند.

سؤال دوم: توصیف پذیری مدل های هوش مصنوعی با استفاده از GRAD-CAM

بخش اول: GRAD-CAM

• زیربخش اول: پرسش و پاسخ

1. CAM یک حالت خاص از Grad-CAM است. تکنیک CAM فقط روی معماری هایی کار می‌کند که در آخرین لایه خود دارای Global Average Pooling (GAP) باشند و بلافاصله بعد از آن به لایه خطی (Softmax) داشته باشند. اگر معماری شبکه ساختار «GAP + لایه خطی» را داشته باشد، وزن‌هایی که Grad-CAM از طریق گرادیان محاسبه می‌کند، برابر با همان وزن‌هایی است که در CAM به صورت مستقیم از لایه آخر یاد گرفته شده. بنابراین در شرایطی که CAM قابل استفاده است، Grad-CAM دقیقاً همان خروجی را می‌دهد، اما Grad-CAM فقط به آن ساختار محدود نمی‌شود. بسیاری از مدل های کلاسیک (مانند VGG) لایه های FC دارند. در CAM مجبور بودیم معماری را تغییر بدیم یعنی لایه FC را حذف کنیم و بجاش GAP بذاریم و شبکه را دوباره آموزش بدیم. در Grad-CAM نیازی به تغییر معماری و Retraining نیست. چون Grad-CAM متکی بر گرادیان یک خروجی Differentiable است، این خروجی می‌تواند هر چیزی باشد: یک برچسب کلاس، کلمه در یک جمله، پاسخ به یک سوال...

مهم‌ترین پیامد عملی این است که برای انتخاب مدل مجبور نیستیم بین دقت و توضیح پذیری یکی رو انتخاب کنیم. می‌تونیم پیچیده‌ترین معماری را بدون دستکاری استفاده کنیم و همچنان Heatmaps داشته باشیم.

2. نویسندگان به این دلیل از تابع ReLU استفاده می‌کنند چون فقط به ویژگی‌هایی اهمیت می‌دن که تاثیر مثبت بر کلاس مورد نظر ما دارند. هدف Grad-CAM تولید نقشه‌ای است که نشان بده کدام نواحی تصویر باعث افزایش Score کلاس خاص شده. وقتی ما گرادیان امتیاز کلاس نسبت به Feature maps را محاسبه میکنیم برخی از این گرادیان‌ها ممکنه منفی باشند که یعنی اگر این بخش از تصویر را تغییر دهیم، امتیاز کلاس مورد نظر کم میشه. نمی‌خواهیم

بدونیم چه چیزی باعث کاهش امتیاز میشه، بلکه می‌خوایم بدونیم چه چیزی باعث افزایش آن شده. ReLU مقادیر منفی را صفر میکند و روی نقاطی تمرکز می‌کند که تاثیر مثبت بر پیش بینی مدل دارند. اگر آن را حذف کنیم، نقاطی که تاثیر منفی بر کلاس دارند در نقشه ظاهر میشوند. این موضوع باعث می‌شود Heatmap نويز پیدا کند. در ثانی دیگر نمی‌توان گفت که بخشی از تصویر باعث کلاس‌بندی صحیح شده. ممکن است نقشه شما بخش‌هایی را هایلایت کند که اتفاقاً علیه آن کلاس هستند. با حذف ReLU نتیجه کار برای انسان غیرقابل تفسیر میشه و دیگه سخت میشه تشخیص داد که چرا مدل این تصمیم را گرفت.

3. یک مدل (VGG-16) را برای تشخیص پزشک از پرستار آموزش دادند. داده‌های آموزشی از موتورهای جستجو جمع‌آوری شد، در حالی که این تصاویر دارای سوگیری جنسیت بودند (78٪ تصاویر پزشک، مرد و 93٪ تصاویر پرستار زن بودند). وقتی مدل روی تصاویر تست Balanced آزمایش شد دقتش افت کرد. Grad-CAM با Heatmap نشان داد که مدل برای تصمیم‌گیری، به چهره و مدل موی افراد نگاه می‌کند و نه به ویژگی‌های شغلی. پس پزشکان زن را پرستار و پرستاران مرد را پزشک پیش بینی میکرد.

مدل‌های یادگیری ماشین اغلب با تکیه بر Spurious Correlation یاد می‌گیرن. این سوگیری‌ها (مثل کلیشه‌های جنسیتی یا نژادی) تو Accuracy دیده نمیشن، اما Grad-CAM آن‌ها را نشون میده. اگر چنین مدلی در دنیای واقعی استفاده شود، تبعیض‌های موجود در جامعه را تکرار و تقویت می‌کند. این آزمایش نشان داد که با استفاده از Grad-CAM می‌توانیم سوگیری‌ها را تشخیص بدیم، داده‌ها را اصلاح و در نهایت مدلی عادلانه‌تر بسازیم.

4. نویسندگان Guided Grad-CAM رو معرفی کردند چون معتقد بودند یک توضیح خوب برای مدل‌های CNN باید دو ویژگی همزمان داشته باشد که هیچ‌کدام از روش‌های قبلی نداشتن: Class-Discriminative یعنی فقط روی همان کلاسی تمرکز کند که مدل پیش‌بینی کرد و High-Resolution یعنی جزئیات تصویر (مثل بافت‌ها یا خطوط) را به صورت دقیق نشان دهد. نقطه ضعف روش‌های مبتنی بر گرادیان این هست که فقط نشان می‌دن که شبکه به چه چیزی نگاه کرده، اما نمی‌توانند بگویند که برای کدام کلاس بوده. نقطه ضعف Grad-CAM این هست که به دلیل استفاده از نقشه‌های ویژگی لایه‌های آخر Heatmap نسبتاً تار است و جزئیات دقیق و لبه‌ها را نشان نمی‌دهد. نویسندگان برای حل این مشکل، این دو روش را با هم ترکیب کردند. Grad-CAM باعث می‌شود فقط بخش‌هایی از تصویر که برای کلاس مورد نظر مهم هستند، باقی بمانند و بقیه حذف شوند. Guided Backpropagation جزئیات ظریف

پیکسلی را بهش اضافه میکنه. در نهایت نقشه ای تولید می‌شود که فقط روی کلاس مورد نظر تمرکز دارد و وضوح پیکسلی دارد.

• زیربخش دوم: پیاده سازی

الف) تصاویر رو به سباز استاندارد 224×224 تبدیل و نرمال سازی انجام شد. مدل ResNet-18 از سیستم لود شد.

ب) بخش Validation دیتاست Tiny-ImageNet با Batch Size=1 لود شد تا بتوانیم تصاویر رو تک به تک بررسی کنیم.

پ) پیدا کردن Correct samples:

برای اینکه خروجی الگوریتم‌ها دقیق باشه، تصاویری انتخاب شد که مدل روی آن‌ها مطمئن است تا Heatmap ها معنادار باشند. پس فقط نمونه‌هایی انتخاب شدند که Confidence مدل در آن‌ها بیش از 80٪ بود.

Sample	Confidence
Thresher	0.81
Barn spider	0.84
Egyptian cat	0.99
Moving van	0.99
European fire salamander	0.84

Table 1_Collected samples

تولید Saliency Maps:

از Vanilla Saliency استفاده شد. هدف این است که بفهمیم هر پیکسل تصویر چقدر در امتیاز نهایی کلاس سهم دارد. مقدار گرادیان خروجی مدل نسبت به تک تک پیکسل‌های تصویر ورودی حساب می‌شه. در کد از تابع `score.backward()` استفاده شد تا گرادیان‌ها به تصویر برگشته و بعد با گرفتن max از روی کانال RGB، تاثیرگذارترین نقاط استخراج بشه. این نقشه نشان می‌دهد که اگر یک پیکسل را خیلی کم تغییر دهیم، امتیاز کلاس هدف چقدر تغییر می‌کند. هرچه مقدار مطلق این گرادیان بیشتر باشد، یعنی آن پیکسل برای مدل مهم‌تر است. برعکس Grad-CAM که مناطق کلی را هایلایت می‌کند، Saliency Map روی لبه‌های تیز و بافت‌های ظریف تمرکز دارد. این روش به جای لایه‌های عمیق، به طور مستقیم با تصویر ورودی درگیر است، به همین دلیل جزئیات خیلی ریزی را نشان می‌دهد. یکی از ویژگی‌های ذاتی این

روش (که در تصویر پایین هم پیدا است) وجود نویز در پس زمینه است، چون مدل حتی به تغییرات کوچک در پیکسل‌های غیر مهم هم واکنش نشان می‌دهد.




Figure 7_Saliency maps

:GradCAM

برعکس روش Saliency که فقط لبه‌ها رو نشان میده، Grad-CAM به ما نشان میده مدل دقیقاً به کدام ناحیه از تصویر برای تصمیم‌گیری تکیه کرده. Target لایه آخر کانولوشنی ('layer4') هدف قرار داده شد، چرا که لایه‌های آخر، ویژگی‌های تصویری مثل شکل کلی یا اجزا را درک می‌کنند. با استفاده از Hook، گرادینان‌ها و Feature Map های این لایه را استخراج و با هم ترکیب شدند تا Heatmap ساخته بشه. ReLU روی ترکیب وزنی ویژگی‌ها زدیم تا فقط پیکسل‌هایی را نگه داریم که تاثیر مثبت در افزایش امتیاز کلاس دارند. در نهایت با انداختن این نقشه روی تصویر اصلی (Overlay)، رفتار مدل را تفسیر شد.




Figure 8_GradCAM visualization

د) Guided Backpropagation:

این روش شبیه Saliency Map است، با این تفاوت که موقع Backward، گرادیانهای منفی حذف میشود. این روش نویزها را به شدت کاهش داده و فقط روی ساختارها و ویژگیهای بصری تمرکز می کند.

Occlusion Map:

میام ورودی رو دستکاری میکنیم. بخش های مختلف تصویر رو با یه مربع سیاه (Patch) می پوشانیم و تغییرات خروجی مدل را بررسی میکنیم. اگر با پوشاندن یک بخش، امتیاز مدل به شدت افت کرد، آن ناحیه با رنگ قرمز مشخص می شه. این روش به ما نشان می ده که مدل چقدر نسبت به نبود یک عضو حساس است. این روش کاملاً مستقل از ساختار داخلی مدل عمل می کند.

Guided Grad-CAM:

این روش از ترکیب Element-wise product خروجی Guided Backprop و Grad-CAM به دست می‌آید. هم دقت پیکسلی Guided Backprop رو داره و هم تمرکز معنایی Grad-CAM رو. این بهمون نشان میده که کدام جزئیات در کدام ناحیه مهم باعث تصمیم‌گیری مدل شدند.






Plot	Top-2 predictions
 Figure 9_guided grad cam for thresher	.Thresher, probability = 0.8067 German short-haired pointer, probability = 0.0432
 Figure 10_guided grad cam for barn spider	Barn spider, probability = 0.8443 Tarantula, probability = 0.098
 Figure 11_guided grad cam for Egyptian cat	Egyptian cat, probability = 0.9173 Cheetah, probability = 0.0407
 Figure 12_guided grad cam for moving van	Moving van, probability = 0.9868 Trailer truck, probability = 0.0057
 Figure 13_guided grad cam for European fire salamander	European fire salamander, probability = 0.8402 Spotted salamander, probability = 0.1489

Table 2_Top-2 Class Interpretability

مدل وقتی به دنبال کلاس دوم (که شاید اشتباه یا شبیه باشه) می‌گرده به بخش‌های متفاوتی از تصویر نگاه می‌کند یا بر روی ویژگی‌های مشترک تمرکز می‌کند.

• زیربخش اول: پرسش و پاسخ

1. نویسندگان مقاله ذکر میکنند که Grad-CAM بر روی چگونگی (How) متمرکز، یعنی به دنبال این پرسش هست که "مدل چگونه به این خروجی رسید؟" Fine-grained classification همیشه مشکل اصلی فرآیند تصمیم‌گیری مدل نیست، بلکه محتوای توضیح (What) است. یعنی "مدل دقیقاً چه ویژگی‌های متمایزکننده‌ای را باید برجسته کند تا تفاوت بین دو کلاس بسیار مشابه مشخص شود؟" وقتی با کلاس‌های بسیار مشابه (مثل دو گونه پرند که فقط در رنگ بال و مدل منقار تفاوت دارند) روبرو هستیم توضیح دادن چگونگی توسط مدل کمکی به درک تمایز نمیکند، در واقع اینجا توضیح باید Discriminative باشد و نه فقط توصیفی. توضیح «چه چیزی» بر روی نقاط تفاوت متمرکز است، در حالی که «چگونگی» فقط مسیر کلی فعال‌سازی را نشان میدهد. نویسندگان معتقدند وقتی مشکل را از چگونگی به چه چیزی تغییر بدیم، راه حل بسیار ساده میشود. به جای طراحی معماری‌های پیچیده و توابع هزینه سنگین برای بهبود Grad-CAM، از Spotting the Difference استفاده میکنند. یعنی توضیح یک کلاس را از توضیح کلاس مشابه دیگر کم کنیم و آن چیزی که باقی میماند ویژگی‌های ظریف متمایزکننده است. این کار بدون نیاز به آموزش مجدد یا تغییر در لایه‌های مدل انجام میشود و با یک عملیات ریاضی ساده روی Activation Maps به دست می‌آید.
 2. وقتی انسان با دو دسته بسیار مشابه مواجه می‌شود، برای تشخیص آنها از یکدیگر توجه‌اش را از ویژگی‌های مشترک برمی‌دارد و مانند بازی Spot-the-difference عمل میکند. مغز ما بعنوان انسان بر روی ویژگی‌هایی تمرکز می‌کند که Discriminative هستند و ویژگی‌هایی که Descriptive کل object هستند رو کنار می‌گذارد. این شهود نشان میدهد که برای درک تفاوت، باید آن بخش‌هایی از تصویر را پیدا کرد که در یک کلاس وجود دارند اما در کلاس مشابه دیگر دیده نمیشوند.
- این شهود از طریق Contrastive Mechanism در سطح وزن‌دهی به Feature Maps پیاده‌سازی میشود. در Grad-CAM، وزن هر کانال a_k^c فقط بر اساس کلاس هدف محاسبه میشود. اما در Finer-CAM، این وزن با مقایسه بین کلاس هدف (c) و کلاس مشابه (d) محاسبه میشود. پیاده‌سازی ریاضی بر پایه Logit Difference است:

$$a_k^{c,d} = \frac{1}{Z} \sum_i \sum_j \frac{\partial(y^c - \gamma \times y^d)}{\partial A_k^{ij}}$$

y^c : Logit کلاس اصلی.

y^d : Logit کلاس مشابه.

γ : ضریب شدت مقایسه.

A_k^{ij} : پیکسل (i, j) در Feature maps استخراج شده توسط فیلتر k ام.

Z : فاکتور Normalization

در نهایت خواهیم داشت:

$$\frac{\partial y^c - \gamma \times y^d}{\partial A_k^{ij}} = \frac{\partial y^c}{\partial A_k^{ij}} - \frac{\partial y^d}{\partial A_k^{ij}}$$

که ساده خواهد شد به صورت:

$$a_k^{c,d} = a_k^c - \gamma \times a_k^d$$

وزن نهایی هر بخش از تصویر، برابر است با اهمیت آن برای کلاس هدف منهای اهمیت آن برای کلاس مشابه. این تفریق باعث می‌شود ویژگی‌های مشترک حذف شده و فقط Fine-grained differences باقی بمانند.

3. γ به عنوان Comparison Strength Coefficient معرفی شده است و تعیین می‌کند مدل

تا چه حد کلاس هدف را با کلاس‌های مشابه مقایسه و تضاد ایجاد کند.

$\gamma \rightarrow 0$: روش Finer-CAM به روش Grad-CAM تبدیل می‌شود و Map Saliency رو

به صورت کلی و Coarse ارائه می‌دهد که معمولا تمام بدنه Object را می‌پوشاند.

$\gamma \rightarrow 1$: تمرکز مدل از کل Object برداشته شده و به سمت جزئیات متمایزکننده میرود. در

واقع γ بالا باعث می‌شود ویژگی‌های مشترک بین کلاس‌های مشابه حذف شده و فقط تفاوت‌های کلیدی هایلایت شوند.

اینطور کاربر بسته به نیاز خود، سطح توضیح‌پذیری را تعیین می‌کند.

در زیست‌شناسی، بسیاری از گونه‌ها از نظر ظاهری خیلی به هم شبیه هستند. Finer-CAM با

استفاده از γ بالا می‌تواند دقیقا روی ویژگی‌های منحصر به فرد که باعث تمایز دو گونه می‌شود

تمرکز کند. این ابزار به دانشمندان کمک می‌کند تا بفهمند آیا مدل هوش مصنوعی واقعا بر

اساس ویژگی‌های علمی و زیستی درست تصمیم گرفته است یا خیر. این روش می‌تواند برای

مکان‌یابی دقیق مفاهیم بصری پیچیده در تصاویر میکروسکوپی یا پزشکی هم استفاده شود.

4. **Finer-CAM** فقط برای مدل‌های تک‌وجهی نیست و می‌تواند به مدل‌های چندوجهی مثل **CLIP** هم تعمیم داده بشه. این تعمیم امکان **Activation Faithfulness Examination** را می‌دهد. با استفاده از این می‌توان **faithfulness** پیش‌بینی طبقه‌بند را بررسی کرد، یعنی بررسی میکند نواحی ای که مدل به‌عنوان دلیل تصمیمش فعال کرده و با **heatmap** نشان می‌دهد، واقعا همان شواهدی باشند که مدل برای تصمیم‌گیری استفاده می‌کند. این آزمون می‌سنجد که توضیح و **Activation map** منطق تصمیم مدل را نشان دهد. چون اعتماد فقط این نیست که مدل درست جواب بده، بلکه مهم است چرا درست یا غلط جواب داده. **Activation faithfulness examination** کمک می‌کند بفهمیم مدل واقعا به ویژگی‌های معنادار و متمایزکننده تکیه کرده (وفادار و قابل اعتمادتر)، یا به پس‌زمینه، نویز، هم‌بستگی‌های جعلی تکیه کرده که در این صورت حتی اگر دقت خوب باشد رفتار مدل شکننده و غیرقابل اعتماد است.

• زیربخش دوم: پیاده‌سازی

الف) مطابق بخش **GradCAM** انجام شد.

ب) به جای اینکه تنها بر روی امتیاز **Target Class** تمرکز کنه، میاد امتیاز ۳ کلاس مشابه (که بالاترین احتمال را بعد از کلاس اصلی دارند) از امتیاز کلاس هدف کم میکنه. (با ضریب $\gamma = 0.8$). این کار باعث می‌شه **heatmap** تولید شده روی ویژگی‌هایی تمرکز کنه که باعث تمایز **Target** از سایر اشیا مشابه میشن.




Figure 14 _Saliency maps for finer grad CAM




Figure 15_Finer grad CAM visualization

هر چه γ به سمت صفر میل کند، مدل به GradCAM نزدیک میشود و هر چی بزرگتر بشه بیشتر به ویژگی های متمایز کننده اهمیت میدهد.

$\gamma = 0.2$ (تمرکز ملایم): نسبت به Grad-CAM استاندارد فیلتر شده است، اما هنوز بخش های نسبتاً بزرگی از شی را پوشش میدهد.

$\gamma = 0.5$ (توازن بهینه): تعادلی میان پوشش کامل شی و حذف نویز برقراره. مرزهای توجه به شدت با مرزهای فیزیکی شیء همپوشانی دارند.

$\gamma = 0.8$ (تمرکز شدید و نقطه ای): نقشه توجه بسیار منقبض و متمرکز می شه و به متمایز کننده ترین جزئیات شی اشاره می کنه که مدل بر اساس آنها تصمیم نهایی را گرفته.

1. زیربخش اول: مقایسه دو روش

در روش Standard Grad-CAM میبینیم که Heatmap بخش‌های وسیعی از تصویر را پوشش میدهد. در روش FinerGrad-CAM با اعمال پارامتر کنترل‌کننده (γ) و حذف اثر کلاس‌های مشابه، heatmap فیلتر شده و نویزهای محیطی حذف شدن. توجه مدل به ویژگی‌های متمایزکننده هستش.




Figure 16_comparison