



به نام خدا



دانشگاه تهران
دانشکده مهندسی برق و کامپیوتر
هوش مصنوعی قابل اعتماد

تمرین چهارم

نام و نام خانوادگی	زکيه امين
شماره دانشجویی	810102398

سؤال اول: FAIRNESS

بخش اول: مبانی و نظریه

پرسش 1: (سه معیار مشاهده‌ای)

الف) معیار Independence: این معیار می‌خواهد نتیجه پیش‌بینی مستقل از ویژگی حساس ما باشد. در واقع Acceptance Rate باید برای گروه‌های مختلف مساوی باشد. یعنی تعلق فرد به یک گروه روی احتمال گرفتن نتیجه مثبت تاثیر نگذارد.
تعریف ریاضی:

$$R \perp A \\ P(\hat{Y} = 1 | A = a) = P(\hat{Y} = 1 | A = b)$$

بطور کلی:

$$P(R = r | A = a) = P(R = r)$$

برای همه مقادیر a و r .

معیار Separation: اگر برچسب واقعی رو بدانیم، آنگاه خروجی مدل نباید به گروه حساس وابسته باشد. یعنی در بین افرادی که واقعا مثبت هستند، Acceptance Rate در همه گروه‌ها برابر باشد و همچنین در بین افرادی که واقعا منفی هستند نیز همین‌طور. اینجا توجه‌امون به Error rate هست که باید تو گروه‌های مختلف یکسان باشد.
تعریف ریاضی:

$$R \perp A | Y$$

باید False Positive Rate و False Negative Rate ها گروه یکسان باشد یعنی:

$$FNR = 1 - TPR$$

$$TPR: P(\hat{Y} = 1 | Y = 1, A = a) = P(\hat{Y} = 1 | Y = 1, A = b)$$

$$FPR: P(\hat{Y} = 1 | Y = 0, A = a) = P(\hat{Y} = 1 | Y = 0, A = b)$$

معیار Sufficiency: اگه خروجی مدل را بدونیم، دیگر دونستن ویژگی حساس نباید اطلاعات اضافهای درباره درست بودن پیش‌بینی بده. یعنی اعتبار پیش‌بینی برای تمام گروه‌ها یکسان باشد.

تعریف ریاضی:

$$Y \perp A | R$$

میشه گفت در این معیار Precision گروه‌ها باید یکی بشه یعنی:

$$P(Y = 1 | \hat{Y} = y, A = a) = P(Y = 1 | \hat{Y} = y, A = b)$$

ب) Independence: برابری جمعیت. تعریف این استاندارد به این صورت هست که نرخ تصمیم مثبت در همه گروه‌ها برابر باشد که متناسب با Independence هستش.

$$P(\hat{Y} = 1 | A = a) = P(\hat{Y} = 1 | A = b)$$

Separation: برابری شانس‌ها. به این صورت هست که هم نرخ مثبت صحیح (TPR) و هم نرخ مثبت کاذب (FPR) باید در گروه‌ها برابر باشد.

$$TPR: P(\hat{Y} = 1 | Y = 1, A = a) = P(\hat{Y} = 1 | Y = 1, A = b)$$

$$FPR: P(\hat{Y} = 1 | Y = 0, A = a) = P(\hat{Y} = 1 | Y = 0, A = b)$$

اگر فقط رابطه اول برقرار باشد، به آن Equal Opportunity گفته می‌شود.

Sufficiency: Predictive Parity یا Calibration within Groups. اگر مدل گفته فرد مثبت، احتمال اینکه واقعا مثبت باشد باید در همه گروه‌ها برابر باشد.

$$P(Y = 1 | \hat{Y} = 1, A = a) = P(Y = 1 | \hat{Y} = 1, A = b)$$

ج) Independence: این معیار جلوی تبعیض مستقیم را می‌گیرد. یعنی مدل نباید فقط به دلیل عضویت تو به گروه خاص، افراد رو بیشتر یا کمتر قبول کنه.

این معیار در استخدام یا پذیرش دانشگاه‌ها مناسبه، چون هدفش جلوگیری از تبعیض اولیه هست و بنابراین برابر بودن Acceptance rate بین دو جنسیت اهمیت زیادی داره. نرخ قبولی‌ها در مردان و زنان باید یکسان باشد.

Separation: جلوی تفاوت در خطاهای مدل رو می‌گیرد. یعنی اگر دو نفر شایستگی یکسان داشته باشند، صرف‌نظر از گروه‌شان باید احتمال قبولی یکسان داشته باشند و همینطور برعکس اگر دو نفر نامناسب باشند، احتمال رد شدنشان باید برابر باشد.

کاربرد این معیار تو سیستم‌های قضایی هست. مطابق مثالی که استاد مطرح کردند سیستمی فرض میکنیم که پیش‌بینی میکند چه کسانی دوباره مرتکب جرم می‌شوند. اگر نرخ مثبت کاذب برای یه نژاد بیشتر باشد، افراد بی‌گناه آن گروه بیشتر به اشتباه پرخطر شناخته می‌شوند. اینجا مهم‌ترین موضوع برابر بودن نرخ خطا میان گروه‌هاست، نه صرفا برابر بودن تعداد افراد پذیرفته‌شده.

Sufficiency: این معیار تضمین می‌کنه که معنای امتیاز مدل برای همه گروه‌ها یکسان باشد. اگر مدل به دو نفر در گروه‌های مختلف امتیاز بالا میده، هر دو باید با احتمال یکسان واقعا موفق شوند.

کاربردش همیشه بانک برای هر متقاضی احتمال بازپرداخت وام پیش‌بینی کند. یعنی مثلاً اگر مدل برای دو گروه مختلف امتیاز ۹۰٪ بده، باید واقعا در هر دو گروه حدود ۹۰٪ افراد وام رو بازپرداخت کنند.

(د) می‌ایم نرخ‌های پایه در دو گروه رو باهم متفاوت در نظر می‌گیریم:

$$P(Y = 1|A = a) \neq P(Y = 1|A = b)$$

با برهان خلف فرض می‌کنیم هم شرط استقلال ($R \perp A$) و شرط بسندگی ($Y \perp A|R$) برقرار است.

براساس قانون احتمال کل نرخ واقعی پایه برای گروه $A = a$ میشود:

$$P(Y = 1|A = a) = \sum_r P(Y = 1|R = r, A = a)P(R = r|A = a)$$

با فرض Sufficiency داریم:

$$P(Y = 1|R = r, A = a) = P(Y = 1|R = r)$$

و همچنین با فرض Independence داریم:

$$P(R = r|A = a) = P(R = r)$$

پس معادله ابتدایی ما تبدیل میشود به:

$$P(Y = 1|A = a) = \sum_r P(Y = 1|R = r)P(R = r)$$

سمت راست معادله از متغیر A مستقل است و برابر میشه با $P(Y = 1)$. پس خواهیم داشت:

$$P(Y = 1|A = a) = P(Y = 1|A = b)$$

این نتیجه با فرض اولیه نرخ‌های پایه ناسازگار در تناقض است.

وقتی نرخ‌های پایه دو گروه متفاوت هستند، برقرار بودن هم‌زمان این دو شرط معمولاً از نظر آماری ممکن نیست. چرا که استقلال مدل رو مجبور می‌کند نرخ پذیرش را در گروه‌ها برابر نگه دارد، در حالی که بسندگی می‌خواهد احتمال درست بودن همان پیش‌بینی‌ها در هر گروه برابر باشد. اختلاف نرخ‌های پایه این دو الزام را با یکدیگر ناسازگار می‌کند.

پرسش 2: (استخراج یک نتیجه عدم امکان) اتحاد چولدچوا

الف) Precision به صورت زیر تعریف می‌شود:

$$PPV = P(Y = 1|\hat{Y} = 1)$$

طبق قانون بیز:

$$PPV = \frac{P(\hat{Y} = 1|Y = 1)P(Y = 1)}{P(\hat{Y} = 1)}$$

برای محاسبه مخرج داریم:

$$P(\hat{Y} = 1) = P(\hat{Y} = 1|Y = 1)P(Y = 1) + P(\hat{Y} = 1|Y = 0)P(Y = 0)$$

$$P(\hat{Y} = 1|Y = 1) = 1 - FNR$$

$$P(\hat{Y} = 1|Y = 0) = FPR$$

$$P(Y = 1) = p, P(Y = 0) = 1 - p$$

پس خواهیم داشت:

$$P(\hat{Y} = 1) = (1 - FNR)p + FPR(1 - p)$$

$$PPV = \frac{(1 - FNR)p}{(1 - FNR)p + FPR(1 - p)}$$

با طرفین وسطین معادله بالا داریم:

$$PPV(1 - FNR)p + PPV(1 - p)FPR = (1 - FNR)p$$

$$PPV(1 - p)FPR = (1 - FNR)p(1 - PPV)$$

$$FPR = \frac{p}{1 - p} \cdot \frac{1 - PPV}{PPV} \cdot (1 - FNR)$$

ب) دو گروه $A \in \{0,1\}$ رو داریم که $p_0 \neq p_1$. رابطه قسمت (الف) را برای هر گروه می‌نویسیم. اگر PPV ، FPR و FNR برابر باشند، در رابطه بخش الف تنها $\frac{p}{1-p}$ متفاوت خواهد بود که چون نرخ پایه دو گروه متفاوت است، پس FPR دو گروه نمیتواند یکسان باشد.

منظور از حالت تباهیده در این سوال، ک حالت استثنایی و غیرعادی است که در آن محدودیت‌های معمول دیگر برقرار نیستند و قضیه به شکل عادی صدق نمی‌کند. مثلاً اگر Classifier هیچ اشتباهی نکند پس:

$$FPR = 0, FNR = 0, PPV = 1$$

دیگه فرقی نمی‌کند نرخ پایه گروه‌ها چقدر باشه، همه معیارهای انصاف می‌توانند هم‌زمان برقرار باشند.

یا اینکه نرخ‌های پایه برابر باشند.

ج) COMPAS برای پیش‌بینی احتمال تکرار جرم متهمان استفاده می‌شد. بررسی ProPublica نشان داد که این سامانه میان گروه‌های نژادی رفتار یکسانی نداره. پژوهش‌های بعدی نشان دادند که علت اصلی، تفاوت نرخ پایه‌ی تکرار جرم در گروه‌هاست. از طرفی شرکت سازنده ادعا می‌کرد که سیستم کالیبره است و برای افراد با یک امتیاز مشخص، احتمال واقعی تکرار جرم در همه گروه‌ها

یکسان است. (همان Predictive Parity ی Sufficiency). اما نشان داده شد که نرخ‌های False Positive Rate و False Negative Rate میان گروه‌ها متفاوت است و معیار Equalized Odds (Separation) برقرار نیست. طبق اتحاد چوداکوف، وقتی نرخ پایه دو گروه متفاوت باشد، نمی‌توان به طور همزمان Predictive Parity و برابری FPR و FNR را برقرار کرد. بنابراین اختلاف میان شرکت سازنده و ProPublica ناشی از این نبود که یکی درست و دیگری غلط باشد، درواقع هر کدام معیار متفاوتی از انصاف را انتخاب کرده بودند که در حضور نرخ‌های پایه متفاوت، جمع کردن آن‌ها از نظر ریاضی امکان‌پذیر نیست.

د) اگر فقط بخواهیم FPR و FNR در دو گروه برابر باشند، این همان معیار Separation است. از نظر ریاضی، برابر بودن همزمان FPR و FNR ممکن است و هیچ تناقضی ندارد. فقط باید آستانه‌های تصمیم‌گیری یا مدل به گونه‌ای تنظیم شوند که این دو نرخ در گروه‌ها برابر شوند. اما اگر نرخ‌های پایه دو گروه متفاوت باشند، در این حالت طبق نتایج معروف، معمولاً نمی‌توان Equalized Odds را همزمان با Predictive Parity (یا PPV برابر) برقرار کرد. طبق الف داریم:

$$FPR = \frac{p}{1-p} \cdot \frac{1-PPV}{PPV} \cdot (1-FNR)$$

اگر نرخ پایه گروه‌ها متفاوت باشد و بخواهیم FPR را برای همه گروه‌ها برابر نگه داریم، در حالی که PPV نیز ثابت باشد، اختلاف عامل $\frac{p}{1-p}$ باید توسط $1-FNR$ جبران بشه. بنابراین FNR ناچار است بین گروه‌ها متفاوت باشد و امکان برابر بودن FPR و FNR (در کنار PPV ثابت) وجود ندارد. در عمل هم اگر آستانه تصمیم‌گیری رو طوری تنظیم کنیم که False Positive Rate در دو گروه برابر شود، معمولاً False Negative Rate تغییر می‌کند. این همان Trade-off میان معیارهای انصاف است که در بسیاری از کاربردها مشاهده می‌شه.

پس ناسازگاری بین معیارهای انصاف یک محدودیت بنیادی و ریاضی است و صرفاً ناشی از کمبود داده یا ضعف مدل نیست. یعنی حتی اگر داده‌های بسیار بیشتری جمع‌آوری کنیم یا مدل را بهتر کنیم تا زمانی که نرخ‌های پایه گروه‌ها متفاوت باشند، نمی‌توان همه معیارهای انصاف را به طور همزمان برقرار کرد (مگر در حالت‌های استثنایی مانند طبقه‌بند کامل).

پرسش 3: (انصاف علی و خلاف واقع)

الف) Counterfactual Fairness بیان می‌کند که یک تصمیم زمانی منصفانه می‌شه که اگر فقط ویژگی حساس فرد را در یک دنیای فرضی تغییر دهیم و همه عوامل دیگر را ثابت نگه داریم، خروجی مدل تغییر نکند. این مفهوم بر پایه Structural Causal Model - SCM تعریف می‌شود. مدل برای هر فرد زمانی Counterfactual Fairness است که:

$$P(\hat{Y}_{A \leftarrow a}(U) = y | X = x, A = a) = P(\hat{Y}_{A \leftarrow \hat{a}}(U) = y | X = x, A = a)$$

برای هر دو مقدار ممکن از ویژگی حساس a و $\hat{a}$.

می‌ایم تو تعریفمون از عملگر $do(A = a)$ استفاده میکنیم. اینطوری به طور مصنوعی مقدار ویژگی حساس را تغییر می‌دیم و سپس اثر آن را بر خروجی بررسی می‌کنیم. تمام متغیرهای زمینه‌ای یا نویزهای ذاتی (U) ثابت نگه داشته می‌شوند. اگر بعد از تغییر مقدار A ، خروجی مدل تغییر نکند، مدل Counterfactually Fair است.

ب) مسیر $A \rightarrow X \rightarrow \hat{Y}$ به Proxy path هست، چرا که متغیر X تحت تاثیر جنسیت قرار گرفته و اطلاعات جنسیت را به مدل منتقل می‌کند. اما مسیر $A \rightarrow \hat{Y}$ مسیر مستقیم تبیین کننده (تبعیض) است. یعنی جنسیت مستقیماً روی تصمیم استخدام اثر می‌گذارد. یال تبعیض رو میشه حذف کرد، اما مسیر Proxy باید بررسی شود که آیا X واقعا نتیجه تبعیض گذشته است یا یک عامل مشروع. اگر تجربه کاری به علت تبعیض‌های قبلی ایجاد شده باشد، این مسیر هم باید حذف شود.

صرف داده‌ها نمی‌توانند تشخیص دهند که اثر جنسیت بر تجربه کاری مشروع است یا ناشی از تبعیض گذشته. مثلاً اینکه زنان به علت تبعیض فرصت شغلی کمتری داشته‌اند، تجربه کمتر آن‌ها نتیجه تبعیض است. اما اگر تجربه ناشی از انتخاب شخصی باشد، شاید استفاده از آن مشروع باشد. بنابراین تشخیص مشروع بودن مسیرها نیازمند قضاوت حقوقی، اخلاقی و سیاست‌گذاری است و صرفاً از داده‌ها قابل استخراج نیست.

ج) این ادعا تا حد زیادی درست است. انصاف خلاف واقعی بر پایه SCM تعریف می‌شود و بدون داشتن مدل علی نمی‌توان جهان خلاف واقعی را ساخت یا عملگر $do(.)$ را اجرا کرد.

دو پژوهشگر ممکن است برای یک مسئله، دو مدل علی متفاوت پیشنهاد دهند. مثلاً یکی به مسیر رو مشروع در نظر می‌گیره و دیگری اون رو مشروع نمیدونه. در نتیجه خروجی تحلیل انصاف نیز متفاوت خواهد شد. این موضوع نشان می‌دهد که انصاف تنها یک مسئله آماری نیست. مدل علی نیازمند فرضیات و قضاوت‌های انسانی درباره روابط علی است و انتخاب ساختار

علی می‌تواند بر نتیجه تحلیل انصاف اثر بگذارد. در نتیجه، هیچ تعریفی از انصاف کاملاً عینی و مستقل از ارزش‌ها و فرضیات نیست و تصمیم‌گیری درباره منصفانه بودن یک سامانه تا حدی به قضاوت انسانی و زمینه کاربرد وابسته است.

بخش دوم: پرسش‌های مفهومی و کاربردی

پرسش 4: (مسئله جانشین/برچسب در سلامت)

الف) در این مسئله، الگوریتم برای شناسایی بیمارانی که به مراقبت ویژه نیاز دارند، هزینه درمان آینده را به جای نیاز واقعی به درمان پیش‌بینی می‌کند. سوگیری‌های موجود عبارت‌اند از: سوگیری برچسب‌گذاری (Label Bias): مدل به جای پیش‌بینی نیاز واقعی بیمار (Need)، متغیر هزینه درمان (Cost) را به عنوان برچسب هدف یاد گرفته است. از آنجا که بیماران محروم معمولاً دسترسی کمتری به خدمات درمانی دارند، هزینه درمان آن‌ها کمتر ثبت می‌شود، در حالی که ممکن است بیماری شدیدتری داشته باشند. بنابراین برچسب انتخاب‌شده نماینده مناسبی برای نیاز واقعی نیست. محل ایجاد سوگیری: مرحله Labeling.

سوگیری اندازه‌گیری (Measurement Bias): هزینه درمان، اندازه‌گیری دقیقی از وضعیت سلامت نیست و تحت تأثیر عواملی مانند درآمد، بیمه، دسترسی به پزشک و تبعیض تاریخی قرار دارد. بنابراین متغیری که اندازه‌گیری شده، با مفهوم واقعی مورد نظر اختلاف دارد. محل ایجاد سوگیری: مرحله اندازه‌گیری.

سوگیری تاریخی (Historical Bias): در گذشته، گروه‌های به حاشیه رانده‌شده (مثل بیماران سیاه‌پوست) به دلیل تبعیض و دسترسی کمتر به خدمات درمانی، هزینه درمان کمتری داشته‌اند. الگوریتم این الگوی تاریخی را یاد گرفته و بازتولید می‌کند. محل ایجاد سوگیری: داده‌های تاریخی مورد استفاده برای آموزش.

سوگیری بازنمایی (Representation Bias): اگر بیماران گروه‌های محروم در داده آموزشی کمتر حضور داشته باشند، مدل الگوی آن‌ها را با دقت پایین‌تری یاد می‌گیرد. محل ایجاد سوگیری: مرحله جمع‌آوری داده.

ب) خیر. حذف نژاد باعث رفع سوگیری نمی‌شود، زیرا بسیاری از ویژگی‌های دیگر اطلاعات مربوط به نژاد را به صورت غیرمستقیم منتقل می‌کنند و نقش Proxy را دارند. علاوه بر این، مشکل اصلی انتخاب متغیر هدف (هزینه) است، نه وجود ویژگی نژاد در داده‌ها. بنابراین حذف ویژگی حساس به تنهایی باعث برقراری انصاف نمی‌شود.

ج) معیار مناسب Separation (Equalized Odds) نسبت به نیاز واقعی بیمار است. دلیل این است که هدف واقعی سیستم، شناسایی بیمارانی است که نیاز بیشتری به مراقبت دارند، نه بیمارانی که هزینه بیشتری ایجاد می‌کنند. اگر دو بیمار (یکی سفیدپوست و یکی سیاه‌پوست) نیاز درمانی یکسانی داشته باشند، باید احتمال انتخاب شدن آن‌ها نیز یکسان باشد. یعنی نرخ‌های TPR و FPR در دو گروه برابر باشد. اما چون مدل بر اساس هزینه درمان آموزش دیده بود، بیماران سیاه‌پوست به دلیل دسترسی کمتر به خدمات درمانی، معمولاً هزینه کمتری داشتند. در نتیجه مدل آن‌ها را کم‌نیازتر تشخیص داد و تعداد زیادی از بیماران واقعاً نیازمند را انتخاب نمی‌کرد (یعنی False Negative بیشتری ایجاد می‌شد). بنابراین اگر عملکرد مدل را نسبت به نیاز واقعی بیمار و با معیار Equalized Odds (برابری TPR و FPR) ارزیابی کنیم، این نابرابری آشکار می‌شود. در مقابل، چون مدل برای پیش‌بینی هزینه آموزش دیده بود، نسبت به هزینه ممکنه کالیبره به نظر برسد. اما این موضوع مشکل اصلی را پنهان کرد، چرا که هزینه فقط یک جانشین برای نیاز درمانی بود و نماینده واقعی آن نبود.

د) به جای پیش‌بینی هزینه درمان آینده، از نیاز واقعی بیمار به عنوان متغیر هدف استفاده شود. مثلاً شدت بیماری، تعداد بیماری‌های مزمن، نتایج آزمایش‌ها، بستری شدن و ... به عنوان برچسب آموزش انتخاب شوند. اینطوری هدف مدل با نیاز واقعی بیماران همسو می‌شود. اثر تبعیض تاریخی ناشی از تفاوت هزینه‌ها کاهش می‌یابد. بیماران محروم بهتر شناسایی می‌شوند. اما از طرفی جمع‌آوری شاخص‌های واقعی سلامت دشوار و پرهزینه است و ممکن است داده‌های پزشکی کامل برای همه بیماران وجود نداشته باشد. همچنین تعریف نیاز واقعی همیشه ساده و یکتا نیست.

ریسک انصاف تازه‌ای که ایجاد می‌شود: با تغییر متغیر هدف به ممکن است دوباره با نوع جدیدی از سوگیری بازنمایی (Representation Bias) مواجه بشیم. افراد متعلق به گروه‌های به حاشیه رانده شده ممکنه به دلیل عدم مراجعه منظم به پزشک متخصص، بیماری‌هایشان اصلاً تشخیص داده نشود. در نتیجه، در پایگاه داده، رکوردهای کمتری دارند. الگوریتم ممکن است مجدداً این فقدان داده ثبت‌شده را به عنوان سلامت فرد تفسیر کند و مجدداً تخصیص منابع به این افراد را کاهش دهد.

اگر شاخص‌های سلامت نیز خود دارای سوگیری باشند، مدل همچنان می‌تواند ناعادلانه عمل کند. تغییر متغیر هدف ممکن است دقت پیش‌بینی هزینه را کاهش دهد. ممکن است بین معیارهای مختلف انصاف مثل Calibration و Equalized Odds ناسازگاری ایجاد شود.

پرسش 5: (انتخاب معیار، تحت قید عدم امکان (اعطای وام)

الف) در مسئله اعطای وام، دو نوع خطا داریم:

False Positive (FP): مدل به فردی که نباید وام بگیرد، وام می‌دهد.

False Negative (FN): مدل به فردی که توان بازپرداخت دارد، وام نمی‌دهد.

ذی‌نفع اول: متقاضیان وام

آسیب تخصیصی همیشه نادیده گرفته شدن شایستگی واقعی، محرومیت از فرصت‌های اقتصادی به دلیل تصمیمات الگوریتم. برای متقاضیان، خطای منفی کاذب به شدت سنگین‌تر از خطای مثبت کاذب است.

هزینه FN: متقاضی فرصت دریافت وام را از دست می‌دهد. حتی اگر فردی شایسته و توانمند در بازپرداخت باشد. این خطا می‌تواند نابرابری اقتصادی را تشدید کند.

هزینه FP: متقاضی وامی دریافت می‌کند که توان بازپرداخت آن را ندارد و ممکن است افت اعتبار مالی شود، اما در لحظه اولیه، رد شدن آسیب مستقیم‌تری به متقاضیان واجد شرایط وارد می‌کند.

ذی‌نفع دوم: بانک

آسیب تخصیصی همیشه زیان مالی مستقیم ناشی از بازپرداخت نکردن وام‌ها یا از دست دادن سهم بازار به دلیل سخت‌گیری بیش از حد. برای بانک، خطای مثبت کاذب به مراتب هزینه‌برتر از خطای منفی کاذب است.

هزینه FP: بانک اصل سرمایه وام داده‌شده به همراه سود متناظر را از دست می‌دهد (زیان مالی مستقیم و قطعی).

هزینه FN: بانک تنها سود موردانتظار حاصل از یک مشتری خوب را از دست می‌ده. زیان یک FP چندین برابر زیان یک FN برای بانک است.

ذی‌نفع سوم: نهادهای ناظر

آسیب تخصیصی همیشه بازتولید تبعیض‌های ساختاری و نابرابری اقتصادی میان گروه‌های حساس و اکثریت در سطح جامعه. برای ناظران، هر دو خطا اگر به صورت غیرمتناسب بر یک گروه خاص تحمیل شوند آسیب‌زا هستند، اما FN سیستماتیک برای گروه‌های حساس تاثیر نامتناسب (Disparate Impact) محسوب می‌شود.

هزینه خطا: ناظر هزینه جریمه‌های قانونی، صدمه به اعتبار بازار مالی و افزایش شکاف طبقاتی جامعه را بابت این خطاهای سیستماتیک می‌پردازد.

ب) مناسب‌ترین انتخاب، معیار برابری فرصت (Equal Opportunity) است که خاصی از معیار Separation / Equalized Odds به شمار می‌رود. این معیار ایجاب می‌کند که نرخ مثبت واقعی برای متقاضیان شایسته در همه گروه‌ها برابر باشد. انتخاب «برابری فرصت» بهینه‌ترین تعادل رو بین دغدغه‌های ذی‌نفعان ایجاد می‌کند.

متقاضیان بیش از هر چیز نگران از دست دادن وامی هستند که توان بازپرداخت آن را دارند (FN). از آنجایی که رابطه $FNR = 1 - TPR$ برقرار است، با برابر کردن TPR در گروه‌های مختلف، عملاً FNR هم برابر می‌شود و اطمینان حاصل می‌شود که هیچ متقاضی شایسته‌ای صرفاً به دلیل تعلق به یک گروه جمعیتی خاص، شانس دریافت وام رو از دست نمی‌دهد.

میشد نسخه سخت‌گیرانه‌تر این معیار یعنی برابری شانس‌ها (Equalized Odds) رو انتخاب کرد، اونوقت مدل مجبور بود FPR رو هم در گروه‌ها برابر کند. اما با تقلیل به برابری فرصت، قید برابری FPR برداشته می‌شه که به الگوریتم بانک اجازه می‌دیم Feasible Space بیشتری داشته باشد تا ریسک‌های مثبت کاذب رو به شکلی مدیریت کند که سود کلی نهاد مالی بیشینه شود. اما از آنجا که این معیار به شایستگی واقعی وابسته است، اگر نرخ‌های پایه تاریخی بازپرداخت در گروه‌ها متفاوت باشد، $P(\hat{Y} = 1|A)$ در گروه‌ها یکسان نخواهد بود. در نتیجه، تخصیص وام نامتناسب میشه و قاعده چهارپنجم نهاد ناظر نقض می‌شود. PPV برای گروه‌های مختلف برابر نخواهد بود. این یعنی نمره اعتباری خروجی مدل، معنای احتمالی کاملاً یکسانی برای اعضای گروه‌های مختلف نخواهد داشت. همچنین برای اینکه افراد شایسته در گروهی با نرخ پایه پایین‌تر شانس برابری برای وام گرفتن داشته باشند، بانک احتمالاً مجبور می‌شه در آن گروه خطای مثبت کاذب بیشتری را بپذیرد (یعنی به افراد فاقد صلاحیت در گروه اقلیت، بیشتر از گروه اکثریت به اشتباه وام بده).

پرسش 6: (داوری مناقشه COMPAS (در پیوند با بخش اول)

الف) ProPublica با بررسی داده‌های خروجی الگوریتم COMPAS نشان داد که این سیستم دارای عدم‌تقارن شدید در خطاهای پیش‌بینی است که به ضرر متهمان سیاه‌پوست عمل می‌کند. FPR برای سیاه‌پوستان دو برابر سفیدپوستان بود. متهمان سیاه‌پوستی که در واقعیت دیگه جرمی مرتکب نمی‌شدند، بسیار بیشتر از سفیدپوستان بی‌گناه، به اشتباه به عنوان پرخطر

برچسب می‌خورند. از طرف دیگر FNR برای سفیدپوستان بالاتر بود که یعنی سفیدپوستان پرخطر بیشتر به عنوان کم‌خطر دسته‌بندی می‌شدند. مبنای استدلال آن‌ها معیار جداسازی بود. Northpointe اینطور از الگوریتمش دفاع کرد که سیستم کاملاً عادلانه است، زیرا نمرات ریسک برای هر دو گروه معنای یکسانی دارند. PPV بین دو گروه برابر بود. اگر الگوریتم به یک فرد سیاه‌پوست و یک فرد سفیدپوست نمره ریسک یکسان می‌داد، احتمال واقعی ارتکاب مجدد جرم برای هر دو نفر برابر بود. مبنای دفاع آن‌ها معیار بسندگی بود.

ب) هر دو طرف از نظر فنی حق داشتند، زیرا به بخش‌های متفاوتی از یک اتحاد ریاضی اجتناب‌ناپذیر نگاه می‌کردند. طبق آنچه تو پرسش 2 اثبات کردیم:

$$FPR = \frac{p}{1-p} \cdot \frac{1-PPV}{PPV} \cdot (1-FNR)$$

Northpointe نشان داد که واسنجی برقرار است، پس $\frac{1-PPV}{PPV}$ برای هر دو نژاد ثابت و برابر است. به دلیل نابرابری‌های تاریخی و ساختاری، نرخ پایه دستگیری مجدد در داده‌های آموزشی برای سیاه‌پوستان بالاتر از سفیدپوستان بود. با قرار دادن یک نرخ پایه بزرگ‌تر در فرمول بالا، در حالی که PPV برای هر دو گروه ثابت نگه داشته شده است، ریاضیات حکم می‌کند که سمت چپ معادله یعنی FPR برای گروه سیاه‌پوست باید بزرگ‌تر شود (یا FNR برای آن‌ها کوچکتر شود، و یا هر دو). بنابراین، Northpointe حق داشت که سیستم کالیبره است، و ProPublica هم حق داشت که FPR نامتناسبی روی گروه اقلیت دارد. این به دلیل اختلاف در نرخ پایه است و برآوردن هم‌زمان آن‌ها ناممکنه.

ج) در زمینه عدالت کیفری و بازداشت پیش از محاکمه، معیار جداسازی باید در اولویت باشد. هزینه مثبت کاذب (قربانی: فرد متهم): در بازداشت پیش از محاکمه، یک مثبت کاذب به معنای حبس کردن فردی است که در واقعیت قرار نبوده جرمی مرتکب شود یا فرار کند. آسیب این خطا ویرانگر، فردی و غیرقابل جبران است و موجب از دست دادن شغل، سرپرستی فرزندان، مسکن، فشار روانی شدید و .. میشود. اینجا هیچ ابزاری برای دفاع از فرد در برابر آسیب ساخته شده نداریم.

هزینه منفی کاذب (FN - قربانی: جامعه): یک منفی کاذب به معنای آزادی موقت فردی است که ممکن است مجدداً جرم کند. آسیب این خطا متوجه امنیت عمومی است. با این حال، جامعه دارای مکانیزم‌ها و ساختارهای پلیس برای مقابله با این خطر است.

پس طبق گفته معروف "بهتر است ده مجرم فرار کنند تا یک بی‌گناه مجازات شود". اگر الگوریتمی کالیبره باشد (معیار Northpointe) اما FPR را به شدت بر یک گروه جمعیتی

حاشیه‌نشین تحمیل کند، عملاً در حال تبدیل شدن به موتور سیستماتیک حبس جمعی برای آن گروه خاص است.

د) بله. این سامانه اصلاً نباید مستقر شود. برای استدلال این موضع، باید از چارچوب معیارهای آماری و مشاهده‌ای خارج شد و به فرآیند تولید داده و SCM نگاه کرد. معیارهای انصاف کلاسیک، خروجی مدل را با برچسب واقعی می‌سنجند، اما در سیستم کیفری، برچسب خودش مخدوش و سوگیرانه است.

COMPAS ارتکاب مجدد جرم رو پیش‌بینی نمی‌کند، بلکه دستگیری مجدد رو پیش‌بینی می‌کند. مسیرهای وابستگی ثانویه مثل شدت حضور پلیس در محله‌های خاص، بودجه‌های نظارتی، و سوگیری‌های نهادینه شده روی دستگیری تاثیر دارند. گراف‌های علی در سیستم کیفری نشان می‌دهند که میان متغیر حساس و برچسب هدف، مسیرهای علی مخربی وجود دارد که ناشی از ویژگی‌های مجرمانه فرد نیست، بلکه ناشی از ساختارهای پلیسی و اقتصادی است. تلاش برای برآوردن معیارهای انصاف ریاضی بر روی داده‌هایی که خروجی یک سیستم ساختاریافته نابرابر هستند، فقط میاد توزیع یک بی‌عدالتی رو عادلانه می‌کند. تا زمانی که نشه اثر علی سوگیری‌های نهادی را از متغیر هدف در پایگاه داده پاکسازی کرد، استفاده از هرگونه مدل یادگیری ماشین، صرفاً سوگیری‌های تاریخی را با ظاهری ریاضیاتی بازتولید و توجیه می‌کند.

پرسش 7: (فرا تر از انصاف حاشیه‌ای: زیرگروه‌ها و زمان)

الف) مفهوم دستکاری زیرگروهی انصاف نشان می‌دهد که چگونه یک مدل می‌تواند معیارهای انصاف را در سطح ویژگی‌های حاشیه‌ای رعایت کند، اما در سطح تقاطع آن ویژگی‌ها به شدت تبعیض‌آمیز عمل کند. مدل به نوعی تبعیض را در زیرگروه‌های ساختاری پنهان می‌کند. فرض کنید یک شرکت 100 متقاضی استخدام دارد که توزیع آن‌ها متقارن است: 50 مرد و 50 زن. 50 سیاه‌پوست و 50 سفیدپوست. در سطح تقاطعی 25 مرد سفیدپوست، 25 زن سفیدپوست، 25 مرد سیاه‌پوست، و 25 زن سیاه‌پوست داریم. حالا فرض کنید الگوریتم تصمیم‌گیری، 50 نفر رو با ترکیب زیر استخدام کند:

25 مرد سفیدپوست (100٪ از این زیرگروه) و 25 زن سیاه‌پوست (100٪ از این زیرگروه)

0 مرد سیاه‌پوست (0٪ از این زیرگروه) و 0 زن سفیدپوست (0٪ از این زیرگروه)

پس نرخ پذیرش مردان: 25 نفر از 50 نفر = 50٪

نرخ پذیرش زنان: 25 نفر از 50 نفر = 50

نرخ پذیرش سفیدپوستان: 25 نفر از 50 نفر = 50٪

نرخ پذیرش سیاهپوستان: 25 نفر از 50 نفر = 50٪

با وجود رعایت کامل انصاف برای نژاد و جنسیت به طور مستقل، الگوریتم در سطح زیرگروه‌ها خیلی بد عمل کرده. نرخ پذیرش برای مردان سیاهپوست و زنان سفیدپوست مطلقاً 0٪ است. الگوریتم‌های یادگیری ماشین بهینه‌سازهای بسیار قدرتمندی هستند. اگر ما فقط قیدهای حاشیه‌ای (Marginal Constraints) را به مدل بدهیم، مدل برای به حداقل رساندن خطای کلی خود، از درجات آزادی باقیمانده استفاده می‌کند تا خطاها را به بخش‌هایی از فضای ویژگی سرریز کند که ما آن‌ها را پایش نمی‌کنیم.

نمی‌توان به سادگی همه زیرگروه‌ها را حساب کرد. این کار با چالش Curse of Dimensionality روبرو است. اگر k ویژگی حساس باینری داشته باشیم، تعداد زیرگروه‌های تقاطعی برابر با 2^k خواهد بود (رشد نمایی). با افزایش ویژگی‌ها در بسیاری از زیرگروه‌های ترکیبی ممکن است تنها چند نمونه محدود یا حتی صفر نمونه در مجموعه داده وجود داشته باشد، در نتیجه محاسبه آماری معنادار انصاف غیرممکن می‌شود. اعمال صدها یا هزاران قید انصاف روی زیرگروه‌های کوچک باعث می‌شود مدل در مرحله آموزش نتواند به همگرایی برسد و دقت آن به شدت سقوط کند.

ب) مفهوم اثر تاخیری نشان می‌دهد که تحمیل کورکورانه معیارهای آماری انصاف می‌تواند در طول زمان نتیجه عکس داده و دقیقاً به همان گروهی که قصد حمایت از آن‌ها را داشتیم، آسیب بلندمدت وارد کند. فرض کنید میانگین نمره اعتباری یک گروه به حاشیه رانده شده، به دلیل بی‌عدالتی‌هایی پایین‌تر از گروه اکثریت است. اگر نهاد ناظر بانک را مجبور کند که معیار برابری جمعیتی را رعایت کند، بانک مجبور است نرخ تایید وام را برای هر دو گروه یکسان کند. برای رسیدن به این نرخ برابر، بانک Threshold را برای گروه به حاشیه رانده شده به شدت پایین می‌آورد. پایین آوردن آستانه باعث می‌شود وام‌های متعددی به افراد پرریسکی داده شود که توانایی واقعی بازپرداخت در آن بازه زمانی را ندارند. این افراد وام را دریافت اما در بازپرداخت اقساط شکست می‌خورند و باعث می‌شود نمره اعتباری این افراد سقوط شدیدی کند. در دوره بعدی ارزیابی، میانگین نمره اعتباری کل گروه اقلیت حتی از نقطه صفر هم پایین‌تر می‌آید. معیار انصاف باعث شد آن‌ها ادر یک چرخه بدهی و افت اعتبار گرفتار و وضعیت اقتصادی آن‌ها

بدتر شود. این پدیده به ما هشدار می‌دهد که ارزیابی ایستا و لحظه‌ای از انصاف یک سراب است. معیارهای سنتی یادگیری ماشین (مثل ماتریس درهم‌ریختگی در لحظه پیش‌بینی) محیط را ایستا فرض می‌کنند. اما تصمیمات الگوریتمی دارای ماهیت علی و پویا هستند و خروجی مدل امروز، ویژگی‌ها و شرایط متقاضیان فردا را تغییر می‌دهد. مداخله منصفانه نباید صرفاً بر اساس برابر کردن $\hat{Y} = f(X)$ در یک لحظه زمانی ارزیابی شود، بلکه باید با مدل‌سازی‌های پویایی سیستم ارزیابی شود که آیا این مداخله در طول زمان منجر به بهبود متغیر افراد می‌شود یا خیر

بخش سوم: پیاده‌سازی و تحلیل تجربی

مرحله 0 – باز تولیدپذیری

مقدار اولیه تولید اعداد تصادفی برابر 98 (دو رقم آخر شماره دانشجویی) در نظر گرفته شد و در تمام بخش‌های دارای مؤلفه تصادفی از همین مقدار استفاده شد.

پالایش استاندارد ProPublica روی داده‌ها اعمال شد که شامل موارد زیر است:

1. نگه داشتن تنها نمونه‌هایی که مقدار days_b_screening_arrest در بازه $[-30, 30]$ قرار دارد.

2. حذف نمونه‌هایی که is_recid = -1 دارند.

3. حذف نمونه‌هایی که c_charge_degree = 'O' دارند.

4. حذف نمونه‌هایی که score_text = 'N/A' دارند.

پس از پالایش، ویژگی هدف (two_year_recid) از سایر ویژگی‌ها جدا شد و ویژگی‌های دسته‌ای با استفاده از One-Hot Encoding به مقادیر عددی تبدیل شدند.

داده‌ها با نسبت 80٪ آموزش و 20٪ آزمون و با استفاده از Stratified Train/Test Split تقسیم شدند تا نسبت کلاس‌های هدف در هر دو مجموعه حفظ شود.

نسخه کتابخانه‌های مورد استفاده:

NumPY	2.4.4
Pandas	3.0.3
Scikit-learn	1.8.0
Fairlearn	0.14.0
Matplotlib	3.10.9

Table 1_Used Libraries

مرحله 1 – ممیزی سوگیری

الف) برای هر گروه نژادی، نرخ پایه وقوع متغیر هدف ($two_year_recid=1$) محاسبه شد. این نرخ نشان‌دهنده نسبت افرادی است که طی دو سال مجدداً مرتکب جرم شده‌اند.

Race	$P(Y = 1)$
African-American	%52.31
Asian	%25.81
Caucasian	%39.09
Hispanic	%37.13
Native American	%45.45
Other	%36.15

Table 2_Bae Rate for different Races




Figure 1_Base Rate of Two-year Recidivism by Race

نتایج نشان می‌دهد که نرخ بازگشت به جرم در میان گروه‌های نژادی یکسان نیست و قبل از آموزش هر مدل نیز اختلاف‌هایی بین گروه‌ها مشاهده می‌شود. این اختلاف می‌تواند در ارزیابی معیارهای انصاف مدل اثر بگذارد.

(ب)




Figure 2_Distribution of COMPAS scores by group

با مقایسه این توزیع‌ها مشاهده می‌شود که نحوه توزیع امتیازهای ریسک در میان گروه‌های مختلف کاملاً یکسان نیست. توزیع امتیازات در گروه سفیدپوستان و سایر گروه‌ها به شدت Right-skewed است. اکثریت قاطع افراد در این گروه‌ها امتیازات ریسک پایین (بین ۱ تا ۴) دریافت کردند و با افزایش امتیاز ریسک، فراوانی افراد با شیب تندی کاهش می‌یابد. توزیع امتیاز برای متهمان سیاه‌پوست تقریباً Uniform است. تعداد متهمان سیاه‌پوستی که امتیاز ریسک بسیار بالا (۸ تا ۱۰) دریافت کرده‌اند، تقریباً با تعداد افرادی که امتیاز پایین دریافت کرده‌اند برابری می‌کند. پیش‌بینی‌های پرخطر بسیار سنگین‌تر به متهمان سیاه‌پوست تخصیص داده شده.

(ج)




Figure 3_Correlation Matrix

حذف ویژگی حساس نژاد برای ایجاد fairness کافی نیست، زیرا این ویژگی به طور غیرمستقیم در سایر متغیرها پنهان شده. با بررسی سطر و ستون race_code در Figure 3، مشاهده می‌شود که این متغیر بیشترین همبستگی را با متغیر priors_count (دستگیری‌های قبلی) دارد. priors_count هم دارای شدیدترین همبستگی مثبت با decile_score است. این تحلیل، ریشه‌ی توزیع نامتقارن امتیازات در بخش (ب) را روشن می‌کند. متغیر priors_count به عنوان یک ویژگی جانشین قدرتمند برای نژاد عمل می‌کند. از آنجا که نرخ دستگیری‌های قبلی به دلایل ساختاری برای یک گروه خاص بالاتر است، الگوریتم با اتکا به این متغیر اثر نژاد را بازتولید کرده و امتیاز ریسک گروه سیاه‌پوست را به صورت سیستماتیک افزایش می‌دهد.

(د) این ممیزی روی داده‌های پایه‌ای، دو هشدار برای هر مدل یادگیری ماشینی دارد که قرار است در آینده روی این مجموعه داده ساخته شود:

شکست قطعی رویکرد Fairness through Unawareness: این ممیزی ثابت می‌کند که حذف صریح ستون نژاد از داده‌های آموزشی، مدل آینده را منصفانه نخواهد کرد. از آنجا که ویژگی حساس نژاد با متغیرهای دیگر مثل تعداد دستگیری‌های قبلی همبستگی دارد، الگوریتم‌های بهینه‌ساز یادگیری ماشین به سرعت این همبستگی‌های پنهان را کشف می‌کنند و مدل جدید سوگیری نژادی را از طریق مسیرهای وابستگی ثانویه یاد می‌گیرد و همان توزیع ناعادلانه‌ای که در هیستوگرام‌ها دیدیم را مجدد بازتولید می‌کند.

آلودگی فرآیند تولید داده و بازتولید سوگیری تاریخی: تفاوت در متغیرهایی مانند priors_count می‌تواند نمایانگر توزیع نامتقارن نظارت پلیس در محله‌های اقلیت‌نشین است. اگر به مدل پیش‌بینی‌کننده صرفاً بر اساس این داده‌های مشاهده‌ای خام و بدون مداخله‌ی علی آموزش ببینیم نه تنها واقعیت را به شکلی بی‌طرفانه پیش‌بینی نمی‌کند، بلکه بی‌عدالتی‌های تاریخی را با ظاهری ریاضیاتی مشروعیت می‌دهد.

مرحله 2 - مدل پایه و سنج‌های دست‌ساز

الف) $ROC-AUC = 0.7186$ و $Accuracy = 0.6583$

ROC-AUC نشان‌دهنده قدرتی متوسط در تفکیک‌پذیری افراد پرخطر و کم‌خطر هستش.

ب و ج)

Race	Count	Selection Rate	TPR	FPR	PPV
African-American	672	0.5238	0.6736	0.3731	0.6449
Caucasian	380	0.3079	0.4771	0.1938	0.6239
Hispanic	107	0.3178	0.4286	0.2462	0.5294
Other	70	0.1571	0.3000	0.0500	0.8182
Asian	5	0.0000	0.0000	0.0000	0.0000
Native American	1	0.0000	0.0000	0.0000	0.0000

Table 3 _Fairness Metrics Table by Racial Group

با ارزیابی خروجی‌های مدل پایه به تفکیک گروه‌های نژادی، عدم‌تقارن‌های زیر به دست آمد:

Demographic Parity Difference: 0.5238. نرخ پذیرش برای متهمان African-American برابر با 0.5238 است، در حالی که این نرخ برای متهمان Caucasian برابر با 0.3079 و برای گروه Asian برابر با 0.0000 است. این شکاف عمیق نشان می‌دهد که مدل، متهمان سیاه‌پوست را با نرخ بسیار بالاتری به عنوان پرخطر پیش‌بینی کرده.

Equal Opportunity / TPR Gap: 0.6736. TPR برای افراد سیاه‌پوستی که در واقعیت مرتکب جرم شده‌اند 0.6736 است، در حالی که این نرخ برای افراد سفیدپوست مجرم تنها 0.4771 است.

FPR Difference: 0.3731. نرخ مثبت کاذب برای متهمان African-American برابر با 0.3731 است، اما این نرخ برای متهمان Caucasian تنها 0.1938 است. این یعنی یک سیاه‌پوست بی‌گناه تقریباً دو برابر یک‌متهم سفیدپوست بی‌گناه احتمال دارد که به اشتباه توسط مدل پایه به عنوان پرخطر برچسب بخورد.

برخلاف FPR و Selection Rate، مقدار PPV برای دو گروه اصلی جامعه یعنی سیاه‌پوستان (0.6449) و سفیدپوستان (0.6239) بسیار به هم نزدیک است. این نشان می‌دهد مدل پایه از نظر Sufficiency نسبتاً متوازن عمل می‌کند (تایید ادعای Northpointe).

گروه‌های کم‌جمعیت‌تر مانند Asian (۵ نمونه) و Native American (۱ نمونه) به دلیل عدم کفایت داده در مجموعه تست، نرخ 0 را ثبت کردند که نشون میده ارزیابی آماری معنادار روی زیرگروه‌های کم‌جمعیت با چالش همراه هست.

مرحله 3 – آزمون «انصاف از طریق ناآگاهی»

در این مرحله، ویژگی حساس Race به همراه سایر ویژگی‌های مستقیم نژادی از مجموعه داده حذف شدند (تعداد ویژگی‌ها از 13 به 8 کاهش یافت) تا مدلی آموزش داده شود که به اصطلاح Fairness through Unawareness باشد.

ROC-AUC = 0.7187 و Accuracy = 0.6526

Race	Count	Selection Rate	TPR	FPR	PPV
African-American	672	0.5193	0.667	0.3701	0.6447
Caucasian	380	0.2947	0.4444	0.1938	0.6071
Hispanic	107	0.3364	0.4286	0.2769	0.5000
Other	70	0.2000	0.3667	0.0750	0.7857
Asian	5	0.0000	0.0000	0.0000	0.0000
Native American	1	0.0000	0.0000	0.0000	0.0000

Table 4_Fairness Metrics Table by Racial Group (Unaware Model)

Demographic Parity Difference: 0.5193. نرخ پیش‌بینی پرخطر برای افراد African-American بیش از 1.7 برابر افراد سفیدپوست است. این شکاف عمیق نشان می‌دهد حذف متغیر نژاد، نابرابری در خروجی را خنثی نکرده.

Equal Opportunity Difference / TPR Gap: 0.667. مدل برای افراد African-American که واقعا مرتکب جرم مجدد می‌شوند، با احتمال بسیار بالاتری پیش‌بینی پرخطر انجام می‌دهد.

FPR Difference: 0.3701

حذف متغیر حساس (Fairness through Unawareness) به هیچ وجه عدالت الگوریتمی را تضمین نمی‌کند. علت این پدیده حضور متغیرهای جانشین (Proxy Features) در دیتاست است (مانند سابقه دستگیری، نوع جرم، سن و ...). متغیرهای باقی‌مانده در مدل، اطلاعات نژاد را به صورت پنهان در خود حمل می‌کنند و مدل بدون اینکه مستقیما متغیر نژاد را ببیند، نابرابری‌های تاریخی و ساختاری موجود در داده‌ها را بازتولید کرده. بنابراین برای دستیابی به حذف نژاد کافی نیست.

مرحله 4 – تعدیل و مقایسه

به منظور کاهش تبعیض دو روش متفاوت شامل روش حین پردازش (In-Processing) با استفاده از کاهش گرادیان نمایی و شانس برابر) و روش پس پردازش (Post-Processing) با بهینه سازی آستانه) روی مدل پیاده سازی شدند و نتایج آن ها با مدل پایه (Baseline) و مدل بی اطلاع از جنسیت/نژاد (Unaware) مقایسه گردید.

روش In-Processing (کاهش گرادیان نمایی با قید Equalized Odds) = این روش مفهوم برابری شانس را هدف قرار میدهد و با اعمال محدودیت در تابع هدف حین یادگیری، همزمان نرخ مثبت واقعی (TPR) و نرخ مثبت کاذب (FPR) را بین زیرگروه ها متوازن می کند. روش Post-Processing (Threshold Optimizer) = این روش بدون تغییر دادن ضرایب درونی مدل اصلی، آستانه های تصمیم گیری نهایی را برای هر گروه نژادی به صورت تفکیک شده بهینه سازی می کند تا به تعادل دلخواه در سنجه های انصاف دست یابد.

	Baseline	Unaware	In-Processing	Post-Processing
Accuracy	0.6583	0.6526	0.6381	0.6267
Demographic Parity Gap	0.5238	0.5193	0.4673	0.4486
Equal Opportunity Gap (TPR)	0.6736	0.6677	0.5686	0.5476
FPR Gap	0.3731	0.3701	0.4308	0.3846

Table 5_Comparison of the performance

Equal Opportunity Gap در روش In-Processing از 0.6736 به 0.5686 و در روش Post-Processing به 0.5476 کاهش یافته که نشان دهنده بهبود عدالت در شناسایی درست موارد بازگشت به جرم (True Positive Rate) بین گروه های مختلف نژادی است. همچنین Demographic Parity Gap در روش پس پردازش به کمترین میزان خود یعنی 0.4486 رسیده است.

شکاف نرخ مثبت کاذب در روش In-Processing از 0.3731 به 0.4308 افزایش یافته است که نشان می دهد تطبیق مدل روی برابری شانس، گاهی ممکن است ناخواسته خطاهای مثبت کاذب را در میان گروه ها نامتوازن تر کند، هرچند در روش پس پردازش این مقدار کنترل شده تر باقی مانده است (0.3846).

برای دستیابی به مدل‌های منصفانه‌تر، مقداری از دقت کلی سیستم کاسته شده است. دقت مدل از 0.6583 (در حالت پایه) به 0.6381 (در روش In-Processing) و 0.6267 (در روش Post-Processing) افت کرده. این افت اندک دقت، Fairness Cost استاندارد در یادگیری ماشین است که برای برقراری تعادل میان کارایی پیش‌بینی و برابری حقوقی پرداخته می‌شود.

مرحله 5 - عدم امکان تجربی و مرز بده‌بستان

(الف)




Figure 4_Pareto Frontier: Trade-off between Accuracy and Fairness

نمودار رسم‌شده، نقطه مدل پایه (رنگ قرمز) را در بالا و سمت راست (با دقت بالا اما شکاف نابرابری زیاد) و خطوط مرز پارتو (Pareto Frontier با رنگ آبی) را برای مدل‌های بهینه‌سازی شده نشان می‌دهد. همان‌طور که مشهود است، کاهش شکاف برابری فرصت از مقدار تقریبی 0.67 در مدل پایه به مقادیر کمتر (حدود 0.57)، با افت دقت کلی مدل همراه است. این خط پارتو به‌خوبی نشان می‌دهد که برای بهبود عدالت باید هزینه کاهش دقت پیش‌بینی رو پذیرفت.

(ب) با بررسی مقادیر عددی گروه‌های مختلف نژادی در خروجی:

گروه African-American دارای بالاترین نرخ انتخاب (0.5238) و بالاترین نرخ مثبت واقعی یا همان TPR (0.6736) است. در مقابل، گروه‌هایی مانند Asian و Native American به دلیل حجم داده‌های کمتر یا الگوهای مدل، مقادیر صفر یا بسیار پایینی در این سنج‌ها ثبت کرده‌اند. گروه‌های Caucasian و Hispanic نیز مقادیر میانی (TPR حدود 0.47 و 0.42) دارند.

اثبات تجربی قضیه عدم‌امکان:

خروجی‌های کمی ما این قضیه را به طور کامل بازتولید و تایید می‌کنند. چونکه تفاوت قابل توجه میان مقادیر PPV (مثلاً 0.64 برای سیاه‌پوستان در برابر 0.62 برای سفیدپوستان و 0.81 برای سایر گروه‌ها) در کنار اختلاف شدید در TPR و Selection Rate وجود دارد، نشان می‌دهد که بهینه‌سازی روی یک سنجه (مثلاً کاهش شکاف TPR) لزوماً به معنای توازن در سایر سنجه‌ها (مثل PPV یا FPR) نخواهد بود و داده‌ها دقیقاً مطابق با پیش‌بینی تئوریک رفتار می‌کنند.

Race	Selection Rate	TPR	PPV	FPR
African-American	0.5238	0.6736	0.6449	0.3731
Caucasian	0.3079	0.4771	0.6239	0.1938
Hispanic	0.3178	0.4286	0.5294	0.2462
Other	0.1571	0.3000	0.8182	0.0500
Asian	0.0000	0.0000	0.0000	0.0000
Native American	0.0000	0.0000	0.0000	0.0000

Table 6 _Quantitative Evaluation of Metrics for Impossibility Assessment

مرحله 6 – ممیزی تقاطعی

	Count	Selection Rate	TPR	FPR	PPV
African-American_Male	554	0.5848	0.7285	0.4259	0.6543
Caucasian_Male	295	0.3356	0.4960	0.2176	0.6263
African-American_Female	118	0.2373	0.3261	0.1806	0.5357
Hispanic_Male	87	0.3563	0.4848	0.2778	0.5161
Caucasian_Female	85	0.2118	0.3929	0.1228	0.6111
Other_Male	61	0.1803	0.3214	0.0606	0.8182
Other_Female	9	0.0000	0.0000	0.0000	0.0000
Hispanic_Female	20	0.1500	0.2222	0.0909	0.6667
Asian_Male	5	0.0000	0.0000	0.0000	0.0000
Native American_Male	1	0.0000	0.0000	0.0000	0.0000

Table 7 _Fairness Metrics Table for Intersectional Subgroups (Race × Sex)

زیرگروه African-American_Male با تعداد نمونه ۵۵۴ نفر، دارای بالاترین نرخ انتخاب (Selection Rate = 0.5848) و بالاترین نرخ مثبت واقعی (TPR = 0.7285) در مقایسه با سایر زیرگروه‌ها است که نشان‌دهنده ریسک بالای پیش‌بینی بازگشت به جرم برای این دسته است. در مقابل، زیرگروه African-American_Female نرخ انتخاب بسیار پایین‌تری دارد.

در Caucasian هم تفاوت چشمگیری بین مردان و زنان دیده می‌شود. نرخ انتخاب مردان سفیدپوست 0.3356 و زنان سفیدپوست 0.2118 است که نشان می‌دهد جنسیت نقش موثری در تغییرات تصمیم‌گیری مدل ایفا می‌کند.

در برخی زیرگروه‌ها مانند Asian_Male یا Native American_Male به دلیل حجم نمونه بسیار پایین، مقادیر سنج‌ها صفر ثبت شده‌اند. باید در تفسیر آماری آن‌ها احتیاط کرد. شکاف‌های تقاطعی:

Demographic Parity Difference: 0.5848

Equal Opportunity Difference (TPR Gap): 0.7285

FPR Difference: 0.4259

مقایسه این شکاف‌ها با شکاف‌های حالت تک‌بعدی نشان می‌دهد که وقتی ابعاد نژاد و جنسیت با یکدیگر ترکیب می‌شوند، شکاف‌ها عمیق‌تر و حادث‌تر می‌شوند (برای مثال شکاف TPR به بیش از 0.72 رسیده است).

بنابراین، حتی اگر در سطح کلان یا حاشیه‌ای توازن نسبی روی خطاهای مدل وجود داشته باشد، ممیزی تقاطعی اثبات می‌کند که انصاف تقاطعی به شدت نقض شده و مدل روی گروه‌های ترکیبی خاص (مانند مردان سیاه‌پوست در مقایسه با سایر ترکیب‌ها) عمل کرد کاملاً نامتوازن و تبعیض‌آمیزی از خود بروز می‌دهد.

سؤال دوم: حریم خصوصی در یادگیری ماشین و یادگیری فدرال

بخش اول: سوالات توضیحی

زیربخش اول: (حساسیت و مکانیزم لاپلاس)

الف) حساسیت سراسری یک تابع بیشترین میزان تغییر در خروجی آن تابع به ازای تغییر اطلاعات یک فرد بین دو دیتاست همسایه است:

$$l_1 \text{ sensitivity: } \Delta_1 = \max_{D_1, D_2} ||f(D_1) - f(D_2)||$$

با تغییر اطلاعات یک خانوار از x_k به x'_k حداکثر تغییر میشه برابر با اختلاف کران‌های بازه مصرف یعنی $100 - 0 = 100$.

میانگین برابر است با کل مصرف تقسیم بر تعداد کل خانوارها:

$$q_1(D) = \frac{1}{1000} \sum_{i=1}^{1000} x_i$$

با تغییر مصرف یک خانوار، مجموع مصرف حداکثر به اندازه 100 واحد تغییر می‌کند. در نتیجه میانگین به اندازه $\frac{100}{1000} = 0.1$ تغییر میکند.

$$\Delta_{q_1} = 0.1 \text{ پس}$$

کل مصرف برابر است با مجموع مصرف تمام خانوارها میشود:

$$q_2(D) = \sum_{i=1}^{1000} x_i$$

با تغییر مصرف یک خانوار، مجموع مصرف حداکثر به اندازه 100 واحد تغییر می‌کند.

$$\Delta_{q_2} = 100 \text{ پس}$$

بردار تعداد خانوارها در 6 الگوی مصرف شامل 6 مولفه است که تعداد خانوارهای حاضر در هر الگو را نشان می‌دهد. هر خانوار می‌تواند حداکثر در دو الگوی مصرف ظاهر شود. وقتی اطلاعات یک خانوار تغییر می‌کند، می‌تواند از دو الگو خارج شده و در دو الگوی دیگر وارد بشه. در بدترین حالت، خروج یک خانوار از دو الگو، مقدار آن دو مولفه را هر کدام 1 واحد کاهش می‌دهد و ورود آن به دو الگوی دیگر، مقدار آن دو مولفه را هر کدام 1 واحد افزایش می‌دهد. یعنی 4 واحد تغییر داریم.

$$\Delta_{q_3} = 4 \text{ پس}$$

(ب)

$$b = \frac{\Delta}{\varepsilon}, \quad \varepsilon = 0.2$$

$$b_1 = \frac{\Delta_{q_1}}{\varepsilon} = \frac{100}{0.2} = 500$$

$$b_2 = \frac{\Delta_{q_2}}{\varepsilon} = \frac{0.1}{0.2} = 0.5$$

$$b_3 = \frac{\Delta_{q_3}}{\varepsilon} = \frac{4}{0.2} = 20$$

زیربخش دوم: (انتشار خصوصی داده‌ها و REPORT NOISY MAX)

الف) میانگین واقعی و کل مصرف واقعی دارای یک رابطه قطعی ریاضی هستند:

$$\text{تعداد} \times \text{میانگین} = \text{مصرف کل}$$

از آنجایی که در مکانیزم لاپلاس، نویزها به صورت تصادفی و مستقل از هم تولید و به هر Query اضافه می‌شوند، این رابطه قطعی پس از تزریق نویز از بین می‌رود. میانگین نویزی 39.3 ($37.5 + 1.8$) و کل مصرف نویزی 36580 ($37500 - 920$) هستند. با جایگزاری در رابطه داریم:

$$39.3 \times 1000 = 39300 \neq 36580$$

مقادیر منتشرشده با یکدیگر ناسازگارند.

یکی از ویژگی‌های مهم دیفرانسیل پرایوسی این است که هرگونه Post-processing روی خروجی‌های نویزی حریم خصوصی را تضعیف نمی‌کند. می‌توانیم مقادیر نویزی مشاهده‌شده را به عنوان نقطه شروع در نظر بگیریم و با تعریف یک تابع هدف (مثلاً کمینه‌سازی خطای میانگین مربعات) تحت قیدهای ساختاری حاکم بر سیستم ($q_2 = q_1 \times 1000$) مقادیر جدید و سازگاری را استخراج کنیم. این رویکرد بهینه‌سازی پس‌پردازش برای اعمال محدودیت‌ها، شباهت زیادی به تنظیم Thresholds برای رسیدن به تعادل در سیستم‌های ارزیابی دارد و خروجی‌هایی را تولید می‌کند که هم به مقادیر نویزی اولیه نزدیک‌اند و هم از نظر منطقی صحیح هستند.

ب) اگر بخواهیم کل بردار شمارش‌ها را منتشر کنیم، باید حساسیت سراسری کل را در نظر بگیریم. که همیشه همون $\Delta_{q_3} = 4$.

$$b = \frac{\Delta_{q_3}}{\epsilon} = \frac{4}{0.4} = 10$$

ج) در Report Noisy Max ما نیازی به انتشار تمام مقادیر نداریم، بلکه تنها قرار است اندیس بزرگترین مقدار (پرتکرارترین الگو) خروجی داده شود. برای این کار، به هر شمارش به صورت جداگانه نویز اضافه می‌کنیم. در این روش، حساسیت بر اساس حداکثر تغییر در یک شمارش منفرد به ازای تغییر اطلاعات یک فرد محاسبه می‌شود. بود یا نبود یک خانوار در یک الگوی خاص مقدار شمارش آن الگو را دقیقاً 1 واحد تغییر می‌دهد پس در اینجا $\Delta = 1$ است.

$$b_{RNM} = \frac{\Delta}{\varepsilon} = \frac{1}{0.4} = 2.5$$

اول noise های فرض شده رو به شمارش ها اضافه میکنیم:

الگوی 1: 310-4=306

الگوی 2: 295+18=313

الگوی 3: 180+9=189

الگوی 4: 160-6=154

الگوی 5: 90+21=111

الگوی 6: 75+2=77

الگوریتم الگویی را انتخاب می کند که بیشترین مقدار نویزی را داشته باشد. بین اعداد بالا، بیشترین مقدار 313 است که به الگوی 2 تعلق دارد. بنابراین خروجی الگوریتم الگوی دوم خواهد بود. الگوی انتخاب شده با الگوی واقعا پرتکرار یکسان نیست. در داده های واقعی، الگوی 1 با 310 تکرار بیشترین مقدار را داشت، اما الگوریتم به دلیل تاثیر نویزها، الگوی 2 را به عنوان خروجی اعلام کرد.

در این حالت دقیق، ترکیب یک نویز منفی برای الگوی اول (-4) و یک نویز مثبت و نسبتا بزرگ برای الگوی دوم (+18) باعث شد جایگاه این دو در خروجی نویزی عوض شود. این اتفاق به خوبی Trade-off حفظ حریم خصوصی را نشان می دهد: ما برای حفظ حریم خصوصی مقداری نویز اضافه کردیم و این کار باعث شد Utility صد درصدی داده از بین برود و در پیدا کردن رتبه اول دچار خطا شویم. با این حال، الگوریتم کاملا هم به بیراهه نرفت. چرا که الگوی دوم با 295 تکرار، نزدیک ترین رقیب به الگوی اول بود و سودمندی داده ها تا حد قابل قبولی حفظ شده است.

زیربخش سوم: (تخصیص بودجه حریم خصوصی و ترکیب مکانیزم ها)

الف) مجموع بودجه های تخصیص یافته به هر درخواست نباید از کل بودجه روزانه بیشتر شود:

$$\varepsilon_1 + \varepsilon_2 + \varepsilon_3 = \varepsilon = 0.6$$

چون می خواهیم دقت میانگین مصرف (خروجی اول) از دو خروجی دیگر بیشتر باشد، باید سهم بیشتری از بودجه کل را به آن اختصاص دهیم. پیشنهاد تخصیص:

بودجه میانگین مصرف: $\varepsilon_1 = 0.4$

بودجه Report Noisy Max: $\varepsilon_2 = 0.1$

بودجه بردار شمارش (مکانیزم گاوسی): $\varepsilon_3 = 0.1$

در مکانیزم‌های دیفرانسیل پرایوسی (مثل لاپلاس و گاوسی)، واریانس و مقیاس نویز تولیدشده با ε رابطه عکس دارد. اختصاص دادن ε بزرگ‌تر به یک درخواست، به معنای تزریق نویز کمتر به خروجی آن است که در نتیجه، Utility و دقت آن نسبت به سایر درخواست‌ها افزایش می‌یابد.

ب) مطابق آنچه در زیربخش اول محاسبه شد حساسیت سراسری تابع میانگین برابر با 0.1 است. پس خواهیم داشت:

$$b = \frac{\Delta}{\varepsilon} = \frac{0.1}{0.4} = 0.25$$

ج) حساسیت l_2 برابر است با حداکثر تغییر در نرم اقلیدسی بردار خروجی به ازای تغییر داده‌های یک خانوار.

هر خانوار حداکثر در ۲ الگو حضور دارد. در بدترین حالت، با تغییر اطلاعات یک خانوار، او از ۲ الگو خارج شده و به ۲ الگوی جدید وارد می‌شود.

$$\Delta_2(f) = \sqrt{(1)^2 + (1)^2 + (-1)^2 + (-1)^2 + 0^2 + 0^2} = 2$$

ابتدا مقدار ثابت c را محاسبه می‌کنیم.

$$c^2 = 2 \ln\left(\frac{1.25}{\delta}\right) = 2 \ln\left(\frac{1.25}{10^{-5}}\right) = 2 \ln(125000)$$

$$c \approx 4.845$$

استفاده از بودجه پیشنهادی قسمت الف $\varepsilon_3 = 0.1$ حداقل مقدار انحراف معیار را به دست می‌آوریم:

$$\sigma \geq \frac{c \Delta_2(f)}{\varepsilon_3} = \frac{4.845 \times 2}{0.1} = 96.9$$

د) طبق قضیه ترکیب متوالی، اگر مکانیزم‌هایی با بودجه روزانه 0.6 به مدت 7 روز متوالی روی دیتاست منتشر شوند Privacy Loss برابر با مجموع آن‌ها خواهد بود:

$$\text{Weekly Privacy Loss} = 7 \times 0.6 = 4.2$$

اگر بخواهیم اتلاف حریم خصوصی کل هفته همچنان حداکثر 0.6 باقی بماند، باید بودجه روزانه را به شدت کاهش دهیم و آن را بر 7 تقسیم کنیم:

$$\varepsilon = \frac{0.6}{7} \approx 0.0857$$

کاهش بودجه روزانه به حدود یک‌هفتم مقدار قبلی، به این معناست که مقیاس نويز تزريقي در هر روز 7 برابر بزرگتر خواهد شد و داده‌های روزانه منتشر شده به شدت نویزی تر شده و *Utility* آن‌ها افت بسیار چشمگیری خواهد داشت.

بخش دوم: سوالات مفهومی

زیربخش اول: (حریم خصوصی، استحکام و یادگیری فدرال)

الف) خیر، یادگیری فدرال به تنهایی و بدون استفاده از مکانیزم‌های یک فناوری حفظ حریم خصوصی کامل محسوب نمی‌شود

بهبود عملی حریم خصوصی (Practical Privacy Improvement): در یادگیری فدرال، داده‌های خام دستگاه کاربر را ترک نمی‌کنند و تنها پارامترهای مدل (مانند گرادیان‌ها یا وزن‌ها) به سرور ارسال می‌شوند. این ساختار از نظر عملی دسترسی مستقیم به داده‌های حساس را محدود می‌کند و یک لایه اولیه از محرمانگی را فراهم می‌سازد.

تضمین رسمی حریم خصوصی (Formal Privacy Guarantee): این مفهوم به معنای داشتن یک اثبات ریاضی و دقیق (مانند Differential Privacy) است تا نشان بده هیچ مهاجمی نمی‌تواند اطلاعات حساس را از خروجی‌های سیستم استخراج کند. یادگیری فدرال پایه این تضمین رسمی رو ندارد. زیرا نشان داده شده است که می‌توان با تحلیل دقیق گرادیان‌های ارسالی، داده‌های اصلی کاربران را از طریق حملات استنتاجی یا Inversion Attacks بازسازی کرد.

ب) بر اساس چارچوب مفهومی مقاله، حریم خصوصی و استحکام دو هدف متمایز هستند که برآورده شدن یکی، لزوماً دیگری را تضمین نمی‌کند. حریم خصوصی بر جلوگیری از نشت اطلاعات حساس تمرکز دارد تا سرور یا سایر کاربران نتوانند به داده‌های محلی افراد پی ببرند. در حالی که استحکام بر حفظ عملکرد و دقت مدل در برابر داده‌های مسموم یا کاربران خرابکار تمرکز دارد. این دو هدف حتی می‌توانند در تضاد باشند. برای دستیابی به استحکام بالا، سرور معمولاً نیاز دارد تا به‌روزرسانی‌های ارسالی کاربران را با دقت بررسی و فیلتر کند تا داده‌های مخرب را شناسایی نماید. این بررسی دقیق

می‌تواند نقض حریم خصوصی باشد. از سوی دیگر، پنهان‌سازی شدید داده‌ها برای حفظ حریم خصوصی، تشخیص ناهنجاری‌ها و آپدیت‌های مخرب را برای سرور دشوارتر می‌کند. البته در مقاله اشاره شده که تکنیک‌هایی مانند حریم خصوصی تفاضلی با محدود کردن تاثیر هر کاربر، می‌توانند به صورت جانبی به استحکام نیز کمک کنند، اما ذات این دو هدف از هم جداست.

(ج) خیر، نمی‌توان ادعا کرد که سامانه B حتما حریم خصوصی بیشتری دارد. چون که بدون وجود مکانیزم‌های دفاعی اضافه (مانند Differential Privacy)، به‌روزرسانی‌های مدل در سامانه B به صورت محافظت‌نشده به سرور ارسال می‌شوند. گرادیان‌های ارسالی حاوی الگوهای بسیار دقیقی از داده‌های آموزشی هستند. یک سرور مهاجم می‌تواند با استفاده از Data Reconstruction Attacks دقیقا همان داده‌های خام کاربر را از روی این به‌روزرسانی‌ها استخراج کند. بنابراین در برابر یک مهاجم پیشرفته سامانه B تنها یک احساس امنیت کاذب ایجاد می‌کند و از نظر ریاضی و قطعی حریم خصوصی بیشتری نسبت به جمع‌آوری مستقیم داده‌ها (سامانه A) تضمین نمی‌کند.

زیربخش دوم: (حملات حریم خصوصی و مسموم‌سازی در یادگیری فدرال)

الف) حملات توضیح‌داده شده در کلاس:

Gradient Leakage Attack

Membership Inference Attack

Byzantine Attack

Free-rider Attack

حملات مطرح شده در مقاله:

Backdoor Attack

Membership Inference Attack

Property Inference Attack

حملات رو بر اساس هدف نهایی مهاجم در یک چارچوب منطقی و استاندارد به سه دسته کلی تقسیم می‌کنیم.

دسته اول - Privacy/Inference Attacks:

- **Gradient Leakage Attack** که در آن مهاجم تلاش می‌کند تا از روی گرادیان‌های ارسال‌شده، داده‌های خام کلاینت‌ها را به صورت کامل بازسازی کند.
- **Membership Inference Attack** که در آن هدف مهاجم فهمیدن این موضوع است که آیا یک نمونه داده خاص در مجموعه داده آموزش کلاینت وجود داشته است یا خیر.
- **Property Inference Attack** که در آن مهاجم ویژگی‌های آماری یا خصوصیات داده‌های آموزش (مثلاً جنسیت افراد) را استنتاج می‌کند بدون اینکه عضو بودن یک نمونه خاص را تشخیص دهد.

در هر دو حمله، هدف مختل کردن یا کاهش دقت مدل نیست، بلکه سرقت بی‌سروصدای اطلاعات محرمانه از طریق مهندسی معکوس به‌روزرسانی‌هاست.

دسته دوم- Robustness / Poisoning Attacks:

- **Byzantine Attack** که در آن یک یا چند کلاینت خرابکار، به‌روزرسانی‌های مخرب و کاملاً دلخواه به سرور ارسال می‌کنند تا از همگرایی مدل جهانی جلوگیری کنند یا دقت آن را به شدت کاهش دهند.
- **Backdoor Attack** که در آن مهاجم با ارسال مدل آلوده، مدل نهایی را وادار به رفتار اشتباه روی ورودی‌های خاص می‌کند. این حمله هدفش تخریب عملکرد مدل است، نه استخراج اطلاعات.

هدف این دسته، تخریب عملکرد، کاهش دقت و از بین بردن پایداری مدل نهایی است.

دسته سوم- Systemic / Incentive-based Attacks:

- **Free-rider Attack** که در آن کلاینت بدون اینکه منابع پردازشی خود را مصرف کند یا داده مفیدی داشته باشد، آپدیت‌های جعلی یا تصادفی می‌فرستد تا فقط در سیستم باقی بماند و به مدل نهایی دسترسی پیدا کند.
- این حمله مستقیماً حریم خصوصی یا دقت را هدف نمی‌گیرد، بلکه سیستم مشارکت عادلانه و پاداش‌دهی در محیط فدرال را مختل می‌کند.

ب) در یادگیری فدرال، سرور هیچ‌گاه به داده خام کاربران دسترسی ندارد و تنها **Model Update** را دریافت می‌کند. بنابراین مهاجم نمی‌تواند مستقیماً داده‌های آموزشی را به سرور تزریق کند، بلکه اثر داده یا هدف خود را از طریق مدل محلی آموزش‌دیده منتقل می‌کند. مقاله نیز بیان می‌کند که

چون داده‌ها هرگز به سرور ارسال نمی‌شوند، هر اثری که با داده مسموم قابل ایجاد باشد، از طریق مسموم‌سازی مدل نیز قابل دستیابی است. به همین دلیل Mode Poisoning نسبت به Data Poisoning تهدید مهم‌تری در Federated Learning است، چرا که داده خام کاربران در اختیار سرور نیست، سرور تنها پارامترهای مدل را مشاهده می‌کند، مهاجم می‌تواند مدل محلی را طوری آموزش دهد که Backdoor در مدل نهایی باقی بماند و سرور بدون دسترسی به داده‌ها تشخیص این تغییرات را به‌سختی انجام می‌دهد.

ج) این حمله نسخه‌ای از Active Membership Inference است که در آن سرور نقش مهاجم را دارد. مقاله بیان می‌کند که این موثرترین حمله سمت سرور است.

سرور یک کلاینت را به عنوان قربانی انتخاب می‌کند. کلاینت ایزوله می‌شود. برخلاف Federated Averaging سرور مدل تجمیع‌شده سایر کاربران را برای کلاینت هدف ارسال نمی‌کند. بنابراین کلاینت فقط بر اساس وضعیت خودش آموزش می‌بیند و اثر داده‌هایش در مدل پررنگ‌تر می‌شود. سرور پیش از ارسال مدل، روی نمونه‌ای که می‌خواهد عضویت آن را بررسی کند Gradient Ascent انجام می‌دهد تا Loss آن نمونه افزایش یابد. اگر آن نمونه واقعا در داده آموزشی کلاینت باشد، SGD هنگام آموزش سعی می‌کند Loss همان نمونه را کاهش دهد. بنابراین گرادینان تولیدشده جهت مشخصی پیدا می‌کند و تغییر محسوسی در مدل ایجاد می‌شود. سرور با مشاهده Update ارسال‌شده تشخیص می‌دهد که آیا نمونه موردنظر در داده آموزشی وجود داشته است یا خیر.

SGD باعث قابل تشخیص شدن نمونه عضو می‌شود. ایده اصلی مقاله این است که هر نمونه آموزشی اثر قابل شناسایی روی گرادینان‌ها دارد. اگر نمونه عضو باشد Gradient Ascent ابتدا Loss آن را زیاد می‌کند. هنگام اجرای SGD، چون نمونه در داده آموزشی وجود دارد الگوریتم در جهت کاهش همان Loss حرکت می‌کند. بنابراین گرادینان بزرگی در خلاف جهت Gradient Ascent ایجاد می‌شود و تغییرات مدل قابل مشاهده است. اما اگر نمونه عضو نباشد آن نمونه اصلا در Mini-batchهای آموزش حضور ندارد. در نتیجه SGD دلیلی برای اصلاح Loss آن ندارد. واکنش گرادینان بسیار کوچک یا تقریبا صفر خواهد بود. به همین دلیل، الگوی گرادینان‌های برگشتی برای نمونه عضو و غیرعضو متفاوت است و سرور می‌تواند از این تفاوت برای تشخیص عضویت استفاده کند. این همان مبنای حمله Isolating Gradient Ascent است که مقاله آن را قوی‌ترین حمله فعال سمت سرور معرفی کرده است.

زیربخش سوم: (مکانیزم‌های دفاعی و مبادله حریم خصوصی-استحکام-سودمندی)

مقاله دو مکانیزم زیر را به عنوان خط پایه برای مقابله با مسموم‌سازی معرفی می‌کند:

Norm Clipping / Bounding: محدود کردن اندازه (نرم L_2) گرادیان‌ها یا به‌روزرسانی‌های ارسالی هر کلاینت به یک آستانه حداکثری مشخص. این کار مانع از آن می‌شود که یک مهاجم با ارسال پارامترهای بسیار بزرگ، مدل جهانی را تحت تسلط خود درآورد.

افزودن نویز: اضافه کردن نویز تصادفی (مانند نویز گوسی) به به‌روزرسانی‌ها برای پنهان کردن تاثیر دقیق هر نمونه داده و کاهش قطعی بودن اثرات مخرب کلاینت‌های مسموم‌کننده. مثلاً روش **Weak Differential Privacy** که این روش با افزودن نویز تصادفی با واریانس مشخص به به‌روزرسانی‌های مدل یا گرادیان‌ها عمل می‌کند تا تاثیر مخرب و شدید به‌روزرسانی‌های ارسالی توسط کلاینت‌های مهاجم را خنثی یا محدود کند.

LDP (Local Differential Privacy): اینجا هر کلاینت پیش از ارسال اطلاعات خود به سرور مرکزی به صورت محلی به گرادیان‌ها یا وزن‌های مدل خود نویز اضافه می‌کند. داده‌هایی که دستگاه کاربر را ترک می‌کنند از پیش‌نویزدار هستند.

CDP (Central Differential Privacy): اینجا کلاینت‌ها به‌روزرسانی‌های واقعی و بدون نویز خود را به سرور ارسال می‌کنند. سرور پس از دریافت و تجمیع تمامی این به‌روزرسانی‌ها، پیش از انتشار مدل جدید به کلاینت‌ها، به کل مدل تجمیع‌شده نویز اضافه می‌کند.

تفاوت بنیادین در محل **Trust Boundary** است. مکانیزم **LDP** در برابر یک سرور نامطمئن یا کنجکاو هم محافظت ایجاد می‌کند، زیرا سرور هرگز گرادیان‌های خام را دریافت نمی‌کند. در حالی که **CDP** نیازمند اعتماد کامل به سرور مرکزی است (سرور داده‌های خام را می‌بیند) و حفاظت آن صرفاً در برابر اشخاص ثالث یا کلاینت‌های دیگری است که مدل نهایی را دریافت می‌کنند.

برای اینکه **CDP** بتواند به طور موثر در برابر حملات مسموم‌سازی یا **Backdoor** مقاومت کند، باید میزان نویز اضافه‌شده در سرور متناسب با حساسیت مدل تنظیم شود تا اثر به‌روزرسانی‌های مخرب بزرگ جبران بشه. در عمل حجم نویزی که برای تضمین این سطح از استحکام به مدل تجمیع‌شده تزریق می‌شود بسیار زیاد است و سیگنال‌های مفید و گرادیان‌های صحیح سایر کاربران از بین میره و منجر به عدم همگرایی مدل یا افت فاجعه‌بار دقت می‌شود.

بر اساس یافته‌های تجربی مقاله برای این سناریو استفاده از رویکرد CDP با فرض ایجاد یک محیط امن در سرور توصیه می‌شود. در مکانیزم LDP هر کلاینت مستقلاً نویز تولید می‌کند و واریانس این نویزها در سرور با هم جمع می‌شود. در یک مجموعه کوچک شامل تنها 10 مشارکت‌کننده، نسبت سیگنال مفید به مجموع نویزهای تولیدی بسیار پایین خواهد بود، که باعث نابودی کامل Utility و دقت مدل می‌شود. در CDP نویز تنها یک بار و به مدل تجمیع‌شده اضافه می‌شود. این ویژگی باعث می‌شود که برای دستیابی به سطح مشخصی از حریم خصوصی آسیب بسیار کمتری به دقت مدل نهایی وارد شود که در کاربردهای حساس پزشکی، حفظ دقت تشخیصی مدل در کنار حریم خصوصی در اولویت قرار دارد.

بخش سوم: سوالات پیاده‌سازی

زیربخش اول: (آماده‌سازی داده‌ها)

بارگذاری و بررسی اولیه داده:

تعداد کل نمونه‌ها = 697932

تعداد کلاس‌ها = 62

تعداد نویسندگان = 100

تعداد نمونه‌های متعلق به هر نویسنده = 6979.32




Figure 5_Sample Images from Subject: Writer_0

ماهیت داده‌های دیتاست FEMNIST شامل تصاویر دست‌نویس کاراکترها و اعداد انگلیسی است. این دیتاست به‌عنوان نسخه Federated شده دیتاست EMNIST شناخته می‌شود و شامل 62 کلاس مختلف (ارقام 0 تا 9، حروف بزرگ A تا Z و حروف کوچک a تا z) است که به صورت تصاویر خاکستری با ابعاد ۲۸ در ۲۸ پیکسل توسط افراد نوشته شده‌اند. داده‌ها در اینجا غیرمتمرکز و وابسته به نویسنده هستند. به این معنا که هر نمونه تصویر متعلق به یک نویسنده مشخص است و سبک نگارش هر فرد می‌تواند ویژگی‌های آماری خاص خود را داشته باشد.

تعریف مجموعه‌های Member و Non-Member

Member Subjects: 70 | Total Images: 488530

Non-Member Subjects: 30 | Total Images: 209402

Active clients in training: 70

ایجاد ساختار Cross-Silo

در این مرحله، سیستم Federated شامل 8 Silo مستقل طراحی شد. داده‌های مربوط به نویسندگان عضو Member به گونه‌ای بین این 8 سازمان توزیع شدند که نمونه‌های متعلق به یک نویسنده می‌توانند به صورت انحصاری در یک سازمان یا به صورت توزیع شده در چند سازمان مختلف قرار گیرند. این روش چند ویژگی مهم ایجاد می‌کند:

ترکیبی از داده‌های متمرکز و پراکنده: بیشتر Subjectها فقط در یک Silo قرار دارند. بخشی از Subjectها بین دو یا سه Silo تقسیم شده‌اند. بنابراین ساختار داده شبیه یک محیط Cross-Silo واقعی است که در آن ممکن است یک فرد با چند سازمان در ارتباط باشد.

ناهمگنی (Non-IID) داده‌ها: هر Silo مجموعه متفاوتی از Subjectها و کلاس‌ها را دریافت می‌کند. در نتیجه توزیع داده‌ها بین سازمان‌ها یکسان نیست و هر Silo دید متفاوتی از داده‌ها دارد.

مشارکت متفاوت Subjectها: Subjectهایی که فقط در یک Silo حضور دارند، تنها از طریق همان سازمان در آموزش مدل مشارکت می‌کنند. اما Subjectهایی که بین چند Silo تقسیم شده‌اند، در چند به‌روزرسانی محلی مختلف نقش دارند.

تنوع در به‌روزرسانی‌های محلی: چون داده‌های برخی Subjectها در چند Silo پخش شده‌اند، اثر آن‌ها در مدل جهانی از طریق چند مسیر مختلف وارد فرآیند تجمیع Federated می‌شود و الگوی مشارکت متنوع‌تری ایجاد می‌کند.

این ساختار برای مطالعه Subject Membership Inference مناسب است، زیرا همپوشانی داده‌ها یا ایزولاسیون آن‌ها بر میزان نشت اطلاعات و توانایی مهاجم در تشخیص حضور یک موضوع تاثیر مستقیم می‌گذارد. این نوع پارتیشن‌بندی باعث می‌شود شرایط آزمایش به محیط‌های واقعی Federated Learning نزدیک‌تر بشود. اگر یک Subject فقط در یک Silo باشد، اثر او بیشتر در همان به‌روزرسانی محلی دیده می‌شود و ممکن است تشخیص عضویت او ساده‌تر باشد. اگر داده‌های

یک Subject بین چند Silo تقسیم شده باشد، اثر آن در چندین به‌روزرسانی توزیع می‌شود و تشخیص عضویت می‌تواند دشوارتر شود.

	Number of images	Share
Silo_0	89565	18.33%
Silo_1	47692	9.76%
Silo_2	61647	12.62%
Silo_3	56995	11.67%
Silo_4	52340	10.71%
Silo_5	43037	8.81%
Silo_6	55830	11.43%
Silo_7	81424	16.67%

Table 8_Cross-Silo Partitioning Report

Subjects in exactly 1 Silo: 51.43%

Subjects in multiple Silos: 48.57%




Figure 6_Subject Distribution Across Silos

51.4% از Subject ها تنها در یک Silo حضور دارند، در حالی که 48.6% از آن‌ها داده‌هایشان بین چند Silo توزیع شده است. این موضوع نشان می‌دهد که روش پارتیشن‌بندی انتخاب‌شده، ترکیبی از Subject های متمرکز و پراکنده را ایجاد کرده است. وجود Subject هایی که تنها در یک Silo قرار دارند،

باعث می‌شود تمام داده‌های آن‌ها از طریق یک سازمان در فرآیند آموزش مشارکت کند. در مقابل Subject‌هایی که در چند Silo حضور دارند داده‌هایشان در چند به‌روزرسانی محلی مختلف مورد استفاده قرار می‌گیرد و اثر آن‌ها در مدل جهانی به صورت توزیع شده ظاهر می‌شود.

از دیدگاه Subject Membership Inference، این ساختار شرایط متنوعی برای ارزیابی حمله فراهم می‌کند. انتظار می‌رود تشخیص عضویت Subject‌هایی که تنها در یک Silo حضور دارند آسان‌تر باشد، زیرا اثر آن‌ها بیشتر در همان به‌روزرسانی محلی متمرکز است. در مقابل، پراکنده شدن داده‌های یک Subject بین چند Silo می‌تواند اثر آن را در مدل جهانی پخش کند و در نتیجه تشخیص عضویت را دشوارتر سازد.



Figure 7_Silo Share of Total Training Data

می‌بینیم که توزیع داده‌ها بین سازمان‌ها کامل یکنواخت نیست، اما اختلاف میان بیشتر Silo‌ها هم بسیار زیاد نیست. بیشترین سهم مربوط به Silo_0 (حدود 18.3٪) و پس از آن Silo_7 (حدود 16.7٪) است، در حالی که Silo_5 با حدود 8.8٪ کمترین سهم از داده‌های آموزشی را در اختیار دارد.

این اختلاف ناشی از روش پارتیشن‌بندی تصادفی است. هر Subject ممکن است در یک، دو یا سه Silo قرار گیرد و تعداد تصاویر هر Subject نیز یکسان نیست. در نتیجه، برخی Silo‌ها به طور طبیعی داده‌های بیشتری نسبت به سایرین دریافت می‌کنند. هیچ Silo بخش بسیار بزرگی از داده‌های آموزشی را در اختیار ندارد و هیچ سازمانی نیز سهم ناچیزی ندارد. این ویژگی باعث می‌شود تمام Silo‌ها در فرآیند یادگیری فدرال مشارکت موثری داشته باشند، در حالی که همچنان ناهمگنی (Non-IID) داده‌ها حفظ می‌شود.

Silo‌هایی که داده‌های بیشتری در اختیار دارند (مثل Silo_0 و Silo_7) تاثیر بیشتری بر مدل جهانی خواهند داشت، در حالی که سهم Silo‌های کوچک‌تر کمتر خواهد بود. این موضوع می‌تواند بر روند همگرایی مدل و همچنین رفتار حملات Subject Membership Inference اثر بگذارد.

زیربخش دوم: (آموزش مدل فدرال)

برای آموزش مدل طبقه‌بندی تصاویر FEMNIST در ساختار فدرییت، از یک شبکه عصبی کانولوشنی (CNN) با مشخصات زیر استفاده شد که شامل دو لایه کانولوشنی (Conv2d) با فیلترهای 16 و 32، لایه‌های Pooling، لایه Flatten و لایه‌های Fully Connected با خروجی نهایی 62 کلاس.

هایپرپارامترها و تنظیمات آموزشی:

- Global rounds = 10
- تعداد انتخاب سیلوها در هر راند = 4 سازمان (به صورت تصادفی از بین 8 سازمان)
- Local Epochs = 1
- Learning Rate = 0.001 با بهینه‌ساز Adam
- Batch size = 256

در هر راند از آموزش:

1. سرور global model را برای سیلوهای منتخب ارسال می‌کند.
 2. هر سیلو مدل دریافتی را با استفاده از داده‌های محلی خود و طی Local epochs به‌روزرسانی می‌کند.
 3. مدل‌های محلی آموزش‌دیده به سرور مرکزی ارسال شده و سرور با استفاده از الگوریتم FedAvg (میانگین‌گیری وزنی از وزن‌های مدل‌ها)، مدل جهانی جدید را استخراج و به‌روز می‌کند.
- مدل در پایان هر راند روی مجموعه Test ارزیابی شد. روند تغییرات دقت و تابع هزینه به شرح زیر است:

	Accuracy	Loss
Round 1	0.6888	1.0578
Round 2	0.7988	0.6274
Round 3	0.8247	0.5286
Round 4	0.8355	0.4845
Round 5	0.8438	0.4548
Round 6	0.8493	0.4347
Round 7	0.8516	0.4234
Round 8	0.8538	0.4143
Round 9	0.8569	0.4039
Round 10	0.8582	0.3988

Table 9_Accuracy and Loss in each Round




Figure 8_Global Accuracy




Figure 9_Global Loss

Final Accuracy : 0.8582275890298813

Final Loss : 0.39882604629581514

روند صعودی دقت و نزولی بودن تابع هزینه نشان‌دهنده همگرایی موفقیت‌آمیز مدل است. عوامل موثر در این همگرایی شامل انتخاب مناسب نرخ یادگیری، استفاده از معماری مناسب CNN برای استخراج ویژگی‌های تصاویر و تجمیع به موقع وزن‌ها توسط الگوریتم FedAvg میشود.

در فرآیند آموزش یادگیری Federated فقط از داده‌های متعلق به مجموعه‌ی Member (توزیع شده بین سیلوها) استفاده شد و داده‌های مربوط به Non-Member به طور کامل و ۱۰۰٪ خارج از چرخه آموزش و دسترس سرور باقی ماندند.

اگر در این مرحله مرز بین داده‌های Member و Non-Member به درستی رعایت نشود و داده‌های Non-Member به نحوی وارد فرآیند آموزش شوند، مدل به مرور ویژگی‌های آن داده‌ها را نیز یاد می‌گیرد. این امر باعث مخدوش شدن و از بین رفتن اعتبار ارزیابی‌های حریم خصوصی (مانند حملات استنتاج عضویت) در ادامه پروژه خواهد شد، چرا که فرض اصلی در حملات استنتاج این است که مدل تحت حمله، داده‌های Non-Member را در طول آموزش به هیچ عنوان ندیده است.

زیربخش سوم: (ارزیابی حملات MEMBERSHIP INFERENCE)

در این بخش، به منظور سنجش میزان نشت اطلاعات و آسیب‌پذیری مدل فدربیت، حملات استنتاج عضویت در دو سطح مختلف پیاده‌سازی و ارزیابی شدند:

حمله در سطح Subject (بر اساس مسیر Loss در طول راندها): بررسی اینکه آیا حضور مجموعه‌ای از داده‌های یک کاربر خاص (Subject) در فرآیند یادگیری فدربیت قابل شناسایی است یا خیر.

حمله در سطح Record (بر اساس آستانه‌گذاری Loss نمونه‌ها): بررسی اینکه آیا یک نمونه تصویر منفرد می‌تواند به عنوان عضو یا غیرعضو تفکیک شود.

	Accuracy	Precision	Recall	F1
Subject-Level Loss Across Attack	0.700	0.700	1.0000	0.8235
Record-Level Loss Threshold Attack	0.5013	0.7012	0.5012	0.584

Table 10_Attacks Results




Figure 10_Loss Across Rounds Attack ROC

تحلیل حمله در سطح Subject (موفقیت آمیز و با آسیب پذیری بالا):
 با دستیابی به دقت 70 درصدی، 1.00 Recall و مقدار برجسته $AUC = 0.867$ در منحنی ROC، مشخص شد که مدل حمله (رگرسیون لجستیک مبتنی بر بردارهای ویژگی Loss Trajectory) توانایی بسیار بالایی در تفکیک کاربران Member از Non-member دارد. مقدار بالای F1-Score نیز پایداری و قدرت این مدل مهاجم را تایید می کند.




Figure 11_Loss Trajectories Across Global Rounds

نمودار روند تغییرات Loss نشان می‌دهد که میانگین خطای کاربران عضو در طول دوره‌های فدریت همواره با شیب ملایمی پایین‌تر از کاربران غیرعضو قرار دارد. این تفاوت ساختاری در مسیر یادگیری، سیگنال آماری قدرتمندی را در اختیار مهاجم قرار می‌دهد تا با استفاده از مدل دسته‌بندی، هویت مشارکت‌کنندگان را استنتاج کند.

تحلیل حمله در سطح Record (حفاظت‌شده و ناموفق):

نتایج این بخش نشان می‌دهد که Accuracy حمله در سطح رکورد روی عدد 0.5013 (معادل 50 درصد یا حدس تصادفی) قرار دارد.




Figure 12_Record-Level Loss Distribution

توزیع مقادیر Loss برای نمونه‌های عضو و غیرعضو همپوشانی بسیار شدیدی دارد. این پدیده به‌وضوح نشان می‌دهد که معماری یادگیری فدریت (به دلیل میانگین‌گیری وزن‌ها و وجود نویز ناشی از تنوع داده‌های درون سیلوها) توانسته است اثر یک نمونه تصویر منفرد را به طور کامل استتار کند و اجازه ندهد مهاجم از طریق آستانه‌گذاری Loss، به عضویت یک رکورد پی ببرد.

حمله در سطح Subject بسیار موفق‌تر از حمله در سطح Record بوده است. این تفاوت نشان می‌دهد که در یادگیری فدریت Client-based، داده‌های کلکسیونی یک Subject ریسک حریم خصوصی بسیار بالاتری نسبت به داده‌های Record آن فرد دارند. این نتایج نشان‌دهنده یک شکاف حریم خصوصی بین سطوح مختلف داده است. معماری استاندارد FedAvg به طور موثری از حریم خصوصی در سطح Record محافظت می‌کند، زیرا نویز آماری ناشی از تنوع داده‌های سایر کاربران حاضر در همان سیلو، اثر یک رکورد تکی را خنثی می‌کند. با این حال، این معماری در سطح Subject فاقد حفاظت کافی است و ریسک بالایی برای افشای اطلاعات حساس مشارکت‌کنندگان در فرآیند یادگیری فدریت وجود دارد. این امر ضرورت استفاده از تکنیک‌های پیشرفته‌تر مانند دیفرانسیل پرایوسی محلی (Local Differential Privacy) را در سطح کلاینت نشون میدهد.

زیربخش چهارم: (دفاع مبتنی بر DIFFERENTIAL PRIVACY)

تئوری دفاع پایه (Record-Level DP / DP-SGD) منطق حفاظتی: در سطح رکورد، حریم خصوصی روی هر نمونه داده یا رکورد منفرد اعمال می‌شود. هدف این است که اگر یک نمونه به دیتاست اضافه یا حذف شود، خروجی مدل تغییر چشمگیری نکند.

مکانیزم Clipping: گرادیان‌ها در هر مرحله آموزش محاسبه می‌شوند. برای اینکه تاثیر مخرب یا بیش از حد یک نمونه روی آپدیت وزن‌ها گرفته شود، Norm گرادیان‌ها به یک آستانه مشخص (clipping norm) محدود می‌شوند. اگر نرم گرادیان از این حد بیشتر شود، به پایین مقیاس می‌شود.

اضافه کردن نویز: پس از کلیپ کردن، نویز تصادفی (معمولاً توزیع گاوسی یا لاپلاس، بر اساس پارامتر σ) به گرادیان‌ها اضافه می‌شود تا استخراج اطلاعات حساس از روی وزن‌های نهایی غیرممکن شود و بودجه حریم خصوصی بشه.

Subject-Level DP تفاوت ساختاری با Record-Level: در یادگیری فدرال یا دیتاست‌های دسته‌بندی‌شده، هر فرد یا Subject ممکن است چندین رکورد یا نمونه متعلق به خود را ارسال کند. اگر از DP معمولی (رکورد-سطح) استفاده شود، داده‌های مختلف یک کاربر از هم تفکیک نشده و حریم خصوصی کل کاربر نقض می‌شود.

مدیریت نمونه‌های منفرد: در Subject-Level DP، واحد حساسیت و حفاظت، کل یک Subject است. یعنی کلیپ کردن و نویزگذاری در سطح تجميع‌شده‌ی داده‌های هر کاربر انجام می‌شود. این کار تضمین می‌کند که حضور یا عدم حضور تمام رکوردهای یک فرد خاص در فرآیند یادگیری فاش نشود، که برای سناریوهای تدافعی در برابر حملات عضویت بسیار قوی‌تر و مناسب‌تر است.

دو برابر کردن انحراف معیار نویز (σ) به صورت تئوری: افزایش نویز باعث قوی‌تر شدن حریم خصوصی می‌شود (کاهش ϵ). با افزایش σ ، دقت مدل افت می‌کند زیرا سیگنال اصلی در میان نویز گم می‌شود، اما در عوض مقاومت در برابر حملات استنتاج عضویت افزایش می‌یابد.

نصف کردن Clipping Norm به صورت تئوری: وقتی آستانه کلیپینگ را کوچک‌تر می‌کنید، گرادیان‌ها بیشتر محدود می‌شوند و تغییرات اعمال‌شده توسط داده‌های پرت (Outliers) یا نمونه‌های خاص خفه می‌شوند. این کار سطح حفاظت را بالا می‌برد اما از طرفی ممکن است Bias ایجاد کند و در نتیجه دقت مدل کاهش پیدا کند.

دو برابر کردن تعداد Roundها به صورت تئوری: در Differential Privacy، با افزایش تعداد راندهای آموزشی یا مراحل تکرار، اصطلاحاً بودجه حریم خصوصی مصرف می‌شود. اگر پارامترهای نویز و کلیپینگ ثابت بمانند اما تعداد راندها دو برابر شود، کل ϵ انباشته‌شده افزایش می‌یابد (یعنی حریم خصوصی ضعیف‌تر می‌شود). دقت مدل ممکن است به دلیل یادگیری بهتر الگوها ابتدا بالا برود، اما از نظر تئوری نویز انباشته‌شده در طول راندهای بیشتر می‌تواند روی پایداری مدل تاثیر بگذارد و حریم خصوصی کلی را تحت شعاع قرار دهد.

همیشه یک Trade-off معکوس میان حریم خصوصی (ϵ) و دقت مدل وجود دارد. هرچه بخواهیم امنیت و حفاظت را بیشتر کنیم (نویز بیشتر، ϵ کمتر)، دقت مدل افت می‌کند.

چالش اصلی در حملات عضویت در سطح کاربر (Subject Membership Inference)، شناسایی حضور یا عدم حضور کل داده‌های یک فرد است. روش Record-Level تنها به سطح نمونه نگاه می‌کند و در برابر همبستگی‌های رکوردهای یک کاربر ضعیف است. به همین دلیل، دفاع Subject-Level با اینکه افت دقت بیشتری دارد، اما برای حل مسئله‌ی Subject Membership سازگارتر و از نظر امنیتی اصولی‌تر است، زیرا سطح واحد حمله و دفاع با یکدیگر هم‌محور هستند.

پ.ن = پیاده‌سازی این قسمت در ادامه عوض شد اما به دلیل اتمام وقت فرصت نشد گزارش نظیر آن نوشته شود. در دیباگ این بخش از ChatGPT در همان ابعادی که سیاست‌های پروژه اجازه میداد استفاده شد.

پیوست الف – اظهارنامه استفاده از هوش مصنوعی

ابزار	برای چه کاری استفاده شد	پرسش/مرحله و شرح استفاده
ChatGPT	یادگیری مفاهیم معیارهای انصاف مختلف	پرسش 1 - ب
Gemini	یادگیری روش های تعدیل (حین پردازش و پس پردازش)	پیاده سازی سوال 1-مرحله 4
Gemini	یادگیری مفهوم ناسازگاری میان خروجی ها و راه حل Post-processing	سوال 2- سوالات توضیحی- زیربخش دوم-الف
Gemini	قضیه ترکیب متوالی	سوال 2-سوالات توضیحی- زیربخش سوم-د